

가동 상태에 따른 조건부 베이지안 어텐션 전달모형: 제조공장 일전 전력 및 일 피크의 확률예측

Anonymous submission

초록

제조공장의 일 피크를 예측하려면 평균 전력 곡선뿐 아니라 비가동일과 가동일의 변동 크기 및 슬롯 간 상관관계를 구분해야 한다. 본 연구는 시간별 생산계획을 입력으로 하는 베이지안 어텐션 전달모형(BAT)에 가동 상태별 날짜 효과와 정상 AR(1) 잔차를 결합한 조건부 정규 BAT를 제시한다. 평균 구조의 희소 어텐션은 유지하되 날짜 효과·혁신 분산·자기상관을 공동우도에서 추정하며, 결국 슬롯은 관측 사이의 전이분포로 적분한다. KAMP 자원 최적화 데이터의 복사일과 계측 결손을 제외한 시간순 검증 5,016슬롯 및 51개 피크 평가일에서 조건부 BAT의 슬롯 R^2 는 0.9619, RMSE는 12.10 kW였다. 기존 BAT의 일 피크 MAE 14.50 kW는 9.16 kW로, 고피크 13일의 MAE 12.47 kW는 4.38 kW로 감소하였다. 그러나 가동일 전체의 피크 MAE와 슬롯 MAE는 악화되었고, 동일 가동유형 기준선의 전체 피크 MAE 6.67 kW를 넘지 못했다. 조건부 모델의 일 피크 90% 구간 포함률은 90.2%였으나 슬롯 포함률은 99.1%로 과도했다. 일부 어텐션 변수의 수렴 진단도 통과하지 못했다. 결과는 상태별 확률 구조의 가능성과 한계를 함께 보여주는 탐색적 근거로 해석한다. 생산실적을 사전 계획으로 간주한 가정과 기존 BAT 기반 시간대 이동의 반사실적 한계도 명시한다.

1 서론

제조공장의 전력 수요는 생산량뿐 아니라 설비가 켜지는 시각, 준비·대기 구간, 하루의 가동 길이에 따라 달라진다. 하루 총사용량을 잘 맞추는 모델이라도 짧은 고부하 구간이나 일 최대전력을 놓칠 수 있다. 반대로 피크를 보수적으로 예측하기 위해 모든 시각의 불확실성을 크게 잡으면, 변동이 작은 비가동일에도 큰 피크를 예측하게 된다. 그래서 슬롯별 평균 오차와 일 피크 오차를 함께 평가해야 한다.

전력 곡선의 최대값은 비선형 함수이므로 주변 예측분포만으로 그 분포를 결정할 수 없다. 같은 평균 곡선이라도 슬롯 간 상관과 잔차 분산에 따라 일 피크의 크기와 초과확률이 달라진다. 실제로 본 데이터의 기존 BAT는 비가동 14일에서 일 피크를 평균적으로 과대예측하면서, 고피크 13일에서는 일 피크 중앙값을 모두 과소예측하였다. 전체에 공통인 예측잡음 구조가 서로 다른 가동 조건을 충분히 표현하지 못한다는 가설을 세울 수 있으나 이 진단만으로 오차의 원인이나 새로운 분포의 적합성이 확정되지는 않는다.

본 연구는 하루의 생산계획으로 알려진 가동 상태에 조건화하여 확률 경로를 모델링한다. 가동유형별 평균곡선과 생산계획 전달항을 유지하면서, 비가동일과 가동일에

서로 다른 날짜 효과 분산, 혁신 분산, 자기상관을 부여한다. 이렇게 하면 생산계획의 시각별 정보를 사용하는 어텐션과 상태별 불확실성을 구분해 검토할 수 있다. 연구 질문은 조건화가 전체 및 고피크일의 예측을 개선하는지, 개선이 슬롯 정확도와 구간 보정에도 일관되는지, 그리고 복잡한 전달항이 단순한 과거 곡선보다 추가 가치를 제공하는지이다.

기여는 세 가지다. 첫째, 알려진 계획 상태와 희소 전달 평균식을 결합한 공동 정규 AR 모형을 구현하고 결국 간격과 사후 추론을 명시한다. 둘째, 공통 잡음 정규 모형, 기존 Laplace BAT, 전달항 제거형, 동일 가동유형 기준선과 튜닝 LightGBM을 같은 검증 표본에서 비교한다. 셋째, 전체 점수 외에 상태별 오차, 피크 구간 폭, 음수 예측 경로 및 수렴 진단을 공개하여 모형이 유용한 조건과 아직 부족한 조건을 구분한다. 조건부 분포 자체의 신규성이나 어텐션의 확정적 우월성을 주장하지 않는다.

2 관련 연구

산업 부하는 생산 상태와 대기 상태가 교대하는 특성을 갖는다. Berk, Hoffmann, and Müller (2018)은 산업 전력의 상태 전환을 반영한 확률예측을 연구하였다. 본 연구도 상태 구분의 필요성을 공유하지만, 당일 생산계획이 주어 진다는 가정 아래 상태를 결정하며 은닉 마르코프 상태 전이를 새로 추정하지 않는다. 계획이 불확실한 현장에서는 이러한 결정적 상태 선택을 별도로 검증해야 한다.

분포의 위치뿐 아니라 척도와 형상도 설명변수의 함수로 모델링하는 접근은 GAMLSS와 같은 분포 회귀에서 체계화되어 있다 (Rigby and Stasinopoulos 2005). 본 연구에서는 이를 가동 상태별 분산과 시간상관에 적용한다. 다만 사용한 모형은 두 상태의 정규 분포와 AR 경로에 한정되며 일반적인 GAMLSS 추정법이나 상태별 임의의 분포족은 구현하지 않았다.

생산 시각과 전력 시각 사이의 관계는 분포지연모형의 커널 관점에서 표현할 수 있다 (Welty et al. 2009). 여기서는 시간 거리로 만든 점수를 sparsemax (Martins and Astudillo 2016)로 정규화하여 희소 가중치를 얻는다. 본 연구의 어텐션은 대규모 Transformer의 자유로운 질의·키 표현보다 제약이 강한 시간 커널이다. 소표본에서 이 구조가 유리할 가능성은 있지만, 단순한 선형 모형이 복잡한 시계열 모형과 경쟁할 수 있다는 결과 (Zeng et al. 2023)를 고려하면 강한 단순 기준선과의 비교가 필수적이다.

확률예측 평가는 점오차와 별도로 예측분포의 정확성을 다루어야 한다 (Gneiting and Raftery 2007). 본 연구는 분위수 기반 CRPS, 구간 포함률 및 피크 초과확률의

항목	크기 또는 처리
원자료 / 15분 슬롯	6,168 / 24,672
복사일 / 그중 1-6월	122 / 121일
첫 fold 유효 학습일	65일
검증 달력 기간	7월 7일-8월 31일
검증 발행 / 관측 존재	56 / 53일
슬롯 평가 표본	5,016개
피크 평가 표본	51일
비가동 / 가동 피크 평가일	14 / 37일
고피크 평가일 ($M_d > C_{90}$)	13일

표 1: 공통 평가 표본. 시드 반복은 관측일을 추가하지 않는다. 고피크 여부는 평가용 사후 분류다.

Brier 점수를 함께 보고한다. 생산 시간대 이동은 이러한 예측분포를 의사결정에 연결하는 후속 응용이지만, 예측 정확도만으로 개입 후 절감 효과가 보장되지는 않는다. 본문 후반의 시간대 이동 분석은 기존 BAT를 이용한 보조 시뮬레이션으로 한정한다.

3 데이터와 예측 문제

3.1 관측 자료와 평가 마스크

KAMP 자원 최적화 데이터의 `okm_augmented_2021.csv`는 2021년 1월 1일부터 9월 14일까지의 257일, 6,168개 시간 행을 포함한다. 각 행의 15분 전력 측정을 펼치면 24,672개 슬롯이 된다. 생산량은 시간별 실적이다. 본 연구는 이 실적을 전달 또는 예측 발행 전에 알려진 생산 계획으로 간주하므로 실제 사전 계획 로그를 이용한 실증 연구와는 구분해야 한다.

일별 전력 곡선이 소수점까지 일치하지만 기상이 다른 완전 복사 115일과 편집 복사 7일을 제외한다. 전력 0인 74개 슬롯은 계측 결손으로 처리하고, 시각 정보가 소실된 7월 13일과 15일의 목표도 마스크한다. 복사일은 학습 목표와 과거 기준곡선 선택에서 모두 제외한다. 이 과정에서 달력상의 186일인 첫 학습 구간에 유효 관측일은 65일만 남는다. 달력 길이나 15분 슬롯 수는 독립된 실제 날짜 표본 수가 아니다.

슬롯 평가는 유효 관측만 사용한다. 일 피크 평가는 관측이 하나 이상 존재하고 계측 결손 슬롯이 4개 이하인 날에 한한다. 부분 관측일에서는 실제값과 모든 모델의 경로 최대값을 동일한 관측 슬롯 집합에서 구한다. 보고한 피크는 해당 평가 마스크에서 구한 최대값이며 누락된 슬롯에 더 큰 실제 피크가 있었을 가능성은 배제하지 않는다.

3.2 정보 집합과 상태 정의

날짜 d 의 00시에 $t = 0, \dots, 95$ 의 전력을 발행한다. 입력 $q_{d,h}$ 는 $h = 0, \dots, 23$ 의 시간별 계획 생산량이다. 예측 발행일 이후의 전력은 모델이 접근하지 못하도록 가린다. 같은 날 뒤쪽 시간의 계획은 사전 정보라는 가정 아래 사용할 수 있다. 이후 검증일에 이미 관측된 앞선 날짜의 전력을 기준곡선으로 사용하는 것은 허용한다.

양수 생산 시간 수 H_d 로 네 가동유형과 이진 가동 상태

를 정의한다.

$$H_d = \sum_{h=0}^{23} \mathbf{1}[q_{d,h} > 0], \quad a_d = \mathbf{1}[H_d > 0], \quad (1)$$

$$k_d = \begin{cases} 0 & H_d = 0, \\ 1 & 1 \leq H_d \leq 12, \\ 2 & 13 \leq H_d \leq 19, \\ 3 & 20 \leq H_d \leq 24. \end{cases}$$

k_d 는 평균구조를, a_d 는 잡음구조를 선택한다. 가동일 내부에서 $q_{d,h} = 0$ 인 시간은 하루 전체가 비가동인 상태와 다르다. 현재 모형의 잡음 상태는 하루에 하나이며, 가동일 내부의 생산/무생산 슬롯에 별도 분산을 두지는 않는다.

4 조건부 베이지안 어텐션 전달모형

4.1 생산계획과 평균구조

학습 관측 전력의 표준편차 s_y 로 전력을 나누어 $Y_{d,t} = y_{d,t}/s_y$ 로 둔다. 평균을 빼는 중심화는 하지 않는다. 이후 모수와 분산은 별도 표기가 없으면 이 표준화 단위이며 최종 예측은 kW로 되돌린다. 조건부 정규 모형의 위치 구조는

$$m_{d,t} = b_{k_d,t} + \gamma_{k_d} r_{d,t} + T_{d,t}, \quad (2)$$

$$T_{d,t} = \sum_{c \in \{\text{on}, \log\}} w_{c,k_d} \sum_{h=0}^{23} \alpha_{k_d,t,h} x_c(q_{d,h})$$

이다. $b_{k,t}$ 는 유형별 기본곡선이고 $r_{d,t}$ 는 표준화된 과거 전력 기준곡선이다. 날짜유형은 평일·토요일·일요일의 구분이다. 기준일은 최근 28일 내 가동 여부와 날짜유형이 같은 완전 관측일을 우선하며, 없으면 이전의 같은 가동 여부를 가진 최근 완전 관측일을 쓴다. 이것도 없으면 학습 기간의 유형별 평균곡선을 사용한다. 여기서 가동 여부의 일치하는 네 가동유형의 일치보다 약한 조건이다.

생산 입력은 $x_{\text{on}}(q) = \mathbf{1}[q > 0]$ 와 $x_{\log}(q) = \log(1 + q)/\log(1 + q_{\max})$ 로 나눈다. $q_{\max}$ 는 학습기간의 최대 생산량이다. $k > 0$ 에서는 $w_{c,k} = \exp(\omega_{c,k})$ 이고 $k = 0$ 의 전달 이득은 0으로 고정한다. 가동 유무와 생산 강도를 분리하므로, 생산량이 같은 비율로 늘어도 가동 시간의 변화와는 다른 효과를 낼 수 있다.

구현의 시간 거리를 정확히 반영한 어텐션은 다음과 같다.

$$\delta_{t,h} = (t - 4h - 1.5)/4, \quad (3)$$

$$z_{k,t,h} = -|\delta_{t,h} - c_k|^{\beta_k} / \sigma_k,$$

$$\alpha_{k,t} = \text{sparsemax}(z_{k,t}).$$

상수 1.5는 한 시간에 속하는 네 15분 슬롯 인덱스의 중심이다. 날짜 경계를 순환하는 거리나 별도 고정 창 마스크는 사용하지 않는다. `sparsemax`는 확률 단체로의 유클리드 투영이므로 가중치가 음수가 아니고 합이 1이며 일부 시각에 정확히 0을 부여한다. 폭·형상·지연과 두 이득을 합한 $\theta_k = (\log \sigma_k, \log \beta_k, c_k, \omega_{\text{on},k}, \omega_{\log,k})$ 를 추정한다.

양수 이득은 k_d , 기준곡선과 모수를 고정했을 때 전달 향이 생산량에 대해 비감소하도록 한다. 가동 시간이 바뀌어 다른 유형으로 넘어가면 기본곡선과 기준일도 바뀔 수 있으므로 전체 모델의 전역적 단조성은 보장되지 않는다. 어텐션 지연은 예측상의 시간 정렬이며 설비 예열이나 물리적 인과 지연을 직접 측정할 값이 아니다.

4.2 상태별 낱자 효과와 시간상관

조건부 BAT는 이전 상태 $g_d = a_d$ 에 따라 다음 공동모형을 사용한다.

$$\begin{aligned} Y_{d,t} &= m_{d,t} + u_d + e_{d,t}, \\ u_d | g_d &\sim \mathcal{N}(0, v_{u,g_d}), \\ e_{d,0} | g_d &\sim \mathcal{N}\left(0, \frac{v_{\eta,g_d}}{1 - \rho_{g_d}^2}\right), \\ e_{d,t} &= \rho_{g_d} e_{d,t-1} + \eta_{d,t}, \quad t \geq 1, \\ \eta_{d,t} | g_d &\sim \mathcal{N}(0, v_{\eta,g_d}). \end{aligned} \quad (4)$$

낱자 효과와 혁신은 서로 독립이고 낱자 간 잔차 경로도 독립이다. 낱자 수준의 공통 이동은 u_d , 하루 안의 국소 지속성은 $e_{d,t}$ 가 담당한다. 모수가 주어졌을 때 잔차 공분산은

$$\text{Cov}(Y_{d,t}, Y_{d,s} | m, g) = v_{u,g} + \frac{v_{\eta,g}}{1 - \rho_g^2} \rho_g^{|t-s|} \quad (5)$$

이다. 공통 잡음 정규 BAT는 $g_d = 0$ 으로 고정한 비교 모형으로, 평균·사전분포·추론법은 같고 두 상태가 잡음 모수를 공유한다.

기존 BAT는 Laplace 슬롯 우도로 평균을 학습한 뒤 학습 잔차에서 추정된 낱자 변동과 AR 잡음을 예측 경로에 더한다. 반면 식 (4)는 낱자 효과와 AR 분포를 학습 우도에 함께 넣는다. 그래서 기존 BAT와 조건부 BAT는 상태 구분뿐 아니라 분포족과 공동 추론 방식도 다르며 조건화 자체의 효과는 두 정규 BAT의 비교로 판단한다.

4.3 결측 간격을 고려한 가중 우도

낱자 d 의 관측 시각을 $t_{d,1} < \dots < t_{d,n_d}$ 라 하자. 이후 관측의 간격은 $\Delta_{d,j} = t_{d,j} - t_{d,j-1}$ 이다. AR의 결측 상태를 적분하면

$$\begin{aligned} e_{d,t_{d,j}} | e_{d,t_{d,j-1}}, g &\sim \mathcal{N}\left(\rho_g^{\Delta_{d,j}} e_{d,t_{d,j-1}}, V_{d,j}\right), \\ V_{d,j} &= \frac{v_{\eta,g}(1 - \rho_g^{2\Delta_{d,j}})}{1 - \rho_g^2}. \end{aligned} \quad (6)$$

첫 관측은 시각에 관계없이 정상 주변분포를 사용한다. 보간한 목표를 학습 표본에 더하지 않으며 서로 다른 낱자의 마지막·첫 슬롯을 AR로 연결하지 않는다.

관측 잔차 $E_{d,j} = Y_{d,t_{d,j}} - m_{d,t_{d,j}} - u_d$ 에 대해 첫 관측은 $\phi_{d,1} = 0$, 이후는 $\phi_{d,j} = \rho_g^{\Delta_{d,j}}$ 로 놓는다. 그러면

$$\begin{aligned} A_{d,j} &= \sqrt{\frac{1 - \rho_g^2}{1 - \phi_{d,j}^2}}, \\ z_{d,j} &= A_{d,j}(E_{d,j} - \phi_{d,j}E_{d,j-1}), \\ f_{d,j} &= \frac{A_{d,j}}{\sqrt{2\pi v_{\eta,g}}} \exp\left(-\frac{z_{d,j}^2}{2v_{\eta,g}}\right) \end{aligned} \quad (7)$$

이며 첫 관측의 이전 잔차 항은 0으로 해석한다. 정규화 인자 $A_{d,j}$ 도 ρ_g 에 의존하므로 자기상관 갱신에서 이를 생략할 수 없다.

학습 마지막 유효 낱자 $d_{\max}$ 이후 경과 일수에 반감기 30일을 적용한다. 추정 대상은

$$\begin{aligned} \pi(\Theta, \mathbf{u} | \mathcal{Y}) &\propto p(\Theta) \prod_d p(u_d | v_{u,g_d}) \prod_j f_{d,j}^{\lambda_d}, \\ \lambda_d &= 2^{-(d_{\max}-d)/30} \end{aligned} \quad (8)$$

인 가중 우도 기반 일반화 사후분포다. 낱자 효과의 사전 분포에는 시간 가중을 다시 곱하지 않는다. 최근 관측을 강조한다는 점에서 일반적인 비가중 베이지안 모형과 구분된다.

4.4 사전분포와 계산

순환 2차 차분행렬 D_2 로 $Q = D_2^\top D_2 + 10^{-4} I_{96}$ 를 만든다. 유형별 기본곡선은 GMRF 평활화 (Rue and Held 2005)에 따라

$$\begin{aligned} \mathbf{b}_k | \tau_k &\sim \mathcal{N}(0, \tau_k Q^{-1}), \quad \tau_k \sim \text{IG}(1, 0.01), \\ \gamma_k &\sim \mathcal{N}(0, 25), \quad \rho_g \sim \text{Unif}[0, 0.98], \\ v_{u,g}, v_{\eta,g} &\stackrel{\text{ind}}{\sim} \text{IG}(2, 0.01) \end{aligned} \quad (9)$$

를 따른다. $\text{IG}(a, b)$ 는 밀도가 $v^{-a-1} \exp(-b/v)$ 에 비례하는 형태다. 작은 대각항은 Q 를 양의 정부호로 만들며 τ_k 로 나누기 전에 추가한다. 두 상태의 분산은 같은 고정 사전 분포를 갖되 독립이다. 학습되는 상위 모수를 통한 계층적 부분 수축은 구현하지 않았다.

세 가동유형 $k > 0$ 의 θ_k 는 독립 정규 사전분포를 갖는다. 평균은 $(\log 1.5, \log 2, 0, \log 0.3, \log 0.3)$, 표준편차는 $(0.5, 0.5, 1, 1.5, 1.5)$ 이다. 기본곡선과 기준곡선의 선형계수, 낱자 효과, 분산은 조건부 정규 또는 역감마 갱신을 사용한다. 예를 들어 평활 분산은

$$\tau_k | \mathbf{b}_k \sim \text{IG}\left(49, 0.01 + \frac{1}{2} \mathbf{b}_k^\top Q \mathbf{b}_k\right) \quad (10)$$

이고 혁신 분산의 shape에는 가중 관측 수 $\sum_{d: g_d=g} \lambda_d n_d / 2$ 가 더해진다. 낱자 효과 분산에는 가중하지 않은 낱자 수와 $\sum u_d^2$ 가 사용된다.

어텐션 제안에서는 선형계수를 적분한 Metropolis 갱신을 사용한다. 백색화된 선형 설계행렬을 X , 잔차 목표를 r_θ , 대각 가중 정밀도를 W 라 하고 $B = P + X^\top W X$, $h_\theta = X^\top W r_\theta$ 라 두면 로그 수용비는

$$\begin{aligned} \log R &= \frac{1}{2} (h_{\theta'}^\top B^{-1} h_{\theta'} - h_\theta^\top B^{-1} h_\theta) \\ &\quad - \frac{1}{2} (r_{\theta'}^\top W r_{\theta'} - r_\theta^\top W r_\theta) + \log \frac{p(\theta')}{p(\theta)}. \end{aligned} \quad (11)$$

P 는 선형계수의 사전 정밀도다. 이 갱신 중 B 는 어텐션에 의존하지 않아 행렬식 항이 상쇄된다. 제안 수용 여부를 결정한 직후 해당 어텐션에 조건부로 선형계수를 다시 뽑는다. 자기상관은 식 (7)의 정규화 인자를 포함한 랜덤워크 Metropolis로 갱신한다.

최종 실행은 시드 0, 1, 2마다 6,000회 반복하고 앞 3,000회를 버린다. 최초 2,000회 실행에서 수렴 문제가 관측되어 선형계수 적분 갱신과 긴 체인을 적용했으나, 최종 실행에도 일부 어텐션 모수의 수렴 문제가 남았다.

4.5 예측 경로와 피크

예측 날짜의 잠재효과는 새로 $u_d^{(s)}$ 를 뽑고, 정상 초기분포에서 AR 경로 $e_{d,t}^{(s)}$ 를 만든다. 음수 전력을 피하기 위해

$$y_{d,t}^{(s)} = \max\{0, s_y(m_{d,t}^{(s)} + u_d^{(s)} + e_{d,t}^{(s)})\} \quad (12)$$

로 발행한다. 이는 0 이하 표본을 0으로 보내는 절단 처리이며 양수 구간에 다시 정규화한 절단 정규분포가 아니다. 따라서 $s_y m_{d,t}$ 와 최종 경로 평균이 항상 같지는 않다.

평가 관측 집합 $\mathcal{O}_d$ 에서 경로 최대값 $M_d^{(s)} = \max_{t \in \mathcal{O}_d} y_{d,t}^{(s)}$ 를 구한다. 슬롯과 피크의 평균·중앙값·분위수는 모두 같은 경로에서 산출한다. 피크 중앙값은 슬롯 중앙값 곡선의 최대값과 일반적으로 다르다. 학습 가동일 피크의 분위수로 정한 임계값 C 의 원시 초과확률은 $S^{-1} \sum_s 1[M_d^{(s)} > C]$ 이다. Platt 보정 (Platt 1999)은 외부 검증일 이전의 내부 보정 예측에만 적합한다. 아래 분포 비교의 Brier 점수는 보정 전 확률을 사용한다.

5 실험 설계

5.1 시간순 검증과 비교 모형

7월 7일부터 8월 31일까지 14일씩 네 검증 fold를 둔다. 학습은 각 fold 이전으로 확장하되 검증 시작 직전 하루는 gap으로 두어 적합에서 제외한다. 같은 복사 사건에 속하는 날짜도 학습에서 제거한다. gap 날짜의 전력은 이후 예측 시점에 이미 관측된 정보로 참조할 수 있다. 9월 1-14일은 이전 개발에서 확인한 기간이므로 미사용 독립 홀드아웃이 아니다. 이번 조건부 실험과 그림·노트북 재현에서는 9월 목표를 새로 열지 않았다. 검증 기간도 반복적으로 분석했으므로 모든 모델 비교는 탐색적으로 해석한다.

기준선은 최근 동일 가동유형 곡선(B0-kind), 튜닝 LightGBM, 기존 BAT 및 기존 BAT 전달항 제거형이다. B0-kind는 과거 28일의 동일 유형·날짜유형을 우선하고 없으면 이전의 같은 유형, 다음으로 최근 완전 관측일을 사용한다. LightGBM (Ke et al. 2017)은 슬롯용 37개와 일 피크용 37개 설정을 시간순 내부 검증으로 각각 선택하였다. 내부 적합·튜닝·보정 구간을 분리하며 외부 검증 점수로 설정을 고르지 않는다. 각 구간의 입력은 같은 원자료에서 만들지만 BAT의 전체 계획 전달식과 LightGBM의 특성 표현은 같지 않다.

전달항 제거형은 기존 BAT의 학습 단계부터 전달항 전체를 0으로 두고 나머지 모수를 다시 적합한다. 생산 계획에서 정한 유형과 기준일 정보는 남는다. 이 실험은 학습 어텐션과 고정 커널의 차이만 분리한 것도, 조건부 정규 BAT의 제거 실험도 아니다. 신규 두 정규 모형은 같은 평균구조와 추론 설정을 사용하여 상태별 잡음 구분을 비교한다.

신규 모형은 네 fold, 두 잡음 구조, 세 시드의 24개 작업으로 실행했다. 각 작업에서 외부 예측 모형과 내부 보정용 모형을 별도로 적합해 총 48번 적합했다. 내부 보정 모형은 보정일 시작 이전 자료만 사용한다. 기존 기준선은 동일 날짜의 저장 예측을 재사용했고 신규 정규 모형의 결과는 시드별 지표를 계산한 뒤 평균했다. 세 시드는 계산 반복이며 독립적인 관측일이나 앙상블 예측으로 취급하지 않는다.

5.2 평가지표와 비교 원칙

MAE와 WAPE는 예측 중앙값, RMSE와 R^2 및 편향은 예측 평균을 사용한다. 제곱오차와 절대오차의 표적을 명시해 서로 다른 순위를 설명할 수 있게 했다. 유효 표본 $i = 1, \dots, N$ 에서

$$\begin{aligned} R^2 &= 1 - \frac{\sum_i (y_i - \hat{y}_i^{\text{mean}})^2}{\sum_i (y_i - \bar{y})^2}, \\ \text{WAPE} &= 100 \frac{\sum_i |y_i - \hat{y}_i^{\text{med}}|}{\sum_i |y_i|}, \\ \text{Bias} &= N^{-1} \sum_i (\hat{y}_i^{\text{mean}} - y_i) \end{aligned} \quad (13)$$

로 정의한다. R^2 는 상관계수의 제곱이 아니며 음수를 그대로 보고한다. 상수 목표 또는 2개 미만 표본의 R^2 와 분모가 0인 WAPE는 정의하지 않는다. 전체 R^2 는 fold 점수를 단순 평균하지 않고 네 fold의 관측·예측을 합쳐 계산한다.

확률예측에는 5%부터 95%까지 19개 분위수의 pinball 손실로 근사한 CRPS, 50·80·90% 구간 포함률 및 폭을 사용한다. CRPS의 단위도 전력과 같은 kW다. 피크에서는 MAE·RMSE· R^2 , 피크 시점 ± 30 분 적중률, 세 임계값의 평균 Brier를 보고한다. 전체 외에 비가동·가동·고피크 집단으로 나누며, 고피크는 실제 피크가 해당 학습 fold의 C_{90} 보다 큰 날이다. 이 집단 구분은 사후 분석이므로 미래 고피크일을 미리 알 수 있다는 뜻이 아니다.

6 결과

6.1 전체 전력 곡선과 피크

표 2에 같은 평가 표본의 점예측 성능을 제시하였다. 조건부 BAT의 슬롯 R^2 와 RMSE는 비교 모델 중 가장 좋지만, 슬롯 MAE는 기존 BAT 및 전달항 제거형보다 크다. 전체 피크에서는 기존 BAT 대비 MAE가 14.50에서 9.16 kW로 감소하나 B0-kind의 6.67 kW가 가장 작다. 평균과 중앙값의 차이, 큰 오차에 대한 지표의 민감도가 다르므로 단일 순위로 정리하지 않는다.

조건부 모델과 공통 정규 모형의 슬롯 R^2 는 각각 0.9619와 0.9617로 가깝지만 전체 피크 MAE는 15.29에서 9.16 kW로 감소한다. 상태 구분이 평균 곡선의 전반적인 정확도보다 최대값 분포에 더 큰 영향을 준 것으로 보인다. 기존 BAT 대비 전체 피크 MAE 감소율 36.8%에는 분포 추과 공동 학습의 변화도 함께 반영되어 있어 조건화만의 효과로 볼 수 없다.

6.2 상태별 오차와 높은 피크

표 3 및 그림 2에서 개선과 악화가 발생한 집단을 구분하였다. 조건부 모델은 비가동일 피크 MAE를 기존 24.11에서 2.44 kW로 줄였다. 고피크 13일에서도 12.47에서 4.38 kW로 감소했다. 그러나 가동일 전체 MAE는 10.86에서 11.70 kW로 증가했다.

조건부 모델의 가동일 피크 R^2 는 0.8173으로 기존 BAT의 0.8516보다 낮다. 평균 예측의 편향도 가동일 전체에서 +10.11 kW로 남는다. 반면 고피크일의 피크 R^2 는 기존 -3.4261에서 0.4140으로 개선되고, 평균 편향은 -12.24에서 -0.99 kW로 줄어든다. 중간 수준 피크의 과대예측과 높은 피크의 과소예측은 서로 다른 문제로 다뤄야 한다.

모델	슬롯 MAE	슬롯 RMSE	슬롯 R^2	WAPE(%)	피크 MAE	피크 RMSE	피크 R^2
기존 BAT	7.82	12.61	0.9587	8.64	14.50	16.97	0.9516
기존 BAT 전달항 제거	7.73	12.89	0.9568	8.54	14.53	17.13	0.9507
공통 정규 BAT	8.26	12.15	0.9617	9.13	15.29	18.84	0.9404
조건부 정규 BAT	8.34	12.10	0.9619	9.21	9.16	12.25	0.9748
B0-kind	8.51	14.98	0.9417	9.40	6.67	10.03	0.9831
튜닝 LightGBM	11.05	19.78	0.8983	12.20	10.06	17.94	0.9459

표 2: 전체 점예측 평가. 오차 단위는 kW, R^2 는 무차원이다. 신규 정규 모형은 세 시드별 점수의 평균이며 나머지는 저장 예측 한 세트다. 조건부 모형은 어텐션을 포함한다.




그림 1: 저장된 동일 검증 예측의 모델 비교. 전체 점수의 개선은 상태별 오차와 함께 해석한다. 신규 정규 모형의 시드 간 변화는 계산 반복이며 표본 불확실성 구간이 아니다.

모델	비가동	가동	고피크
기존 BAT	24.11	10.86	12.47
기존 BAT 전달항 제거	24.80	10.64	12.27
공통 정규 BAT	30.04	9.71	7.80
조건부 정규 BAT	2.44	11.70	4.38
B0-kind	0.93	8.84	7.54
튜닝 LightGBM	2.51	12.92	18.27

표 3: 집단별 피크 MAE(kW). 표본 수는 비가동 14일, 가동 37일, 고피크 13일이며 고피크는 가동일의 부분집합이다.

전체 R^2 가 높은 데에는 가동·비가동 사이의 큰 수준 차이도 기여한다. 조건부 모형의 비가동일 피크 RMSE는 2.81 kW지만 해당 집단의 피크 R^2 는 -6.40이다. 비가동일 실제 피크의 변동이 매우 작기 때문에 평가 집단 평균보다도 나쁜 상대 점수가 나올 수 있다. 집단별 R^2 는 그 집단의 분산으로 정규화되므로 서로 다른 집단의 수치를 그대로 비교하지 않는다.

6.3 어텐션의 추가 기여

기존 BAT에서 전달항을 없애면 슬롯 MAE는 7.82에서 7.73으로 조금 줄지만 RMSE는 12.61에서 12.89로 늘고 R^2 는 0.9587에서 0.9568로 낮아진다. 전체 피크 MAE도 14.50과 14.53으로 유사하다. 기존 날짜 단위 짝짓기 부트스트랩에서 BAT와 제거형의 슬롯 MAE 차이는 +0.09 kW, 95% 구간은 $[-0.11, +0.30]$ 이었다. 추가 예측 이득은 입증되지 않았지만 제거로 모든 지표가 나아지지도 않는다.

현재 조건부 BAT는 이 전달항을 유지한다. 조건부 구조에서는 전달항을 제거한 비교가 없으므로 고피크 개선이 어텐션 없이 유지되는지는 알 수 없다. 그림 4에 최종 fold의 유형 2 어텐션을 시드별로 제시하였다. 이 어텐션은 시간 가중치를 기술한 것일 뿐이며 체인 수렴과 모수 식별 문제가 있어 정밀한 물리 지연이나 확정적인 설명으로 사용하지 않는다. 후속 비교에서는 조건부 전달항 제거형과 고정 시간 커널을 따로 평가해야 한다.

6.4 구간 보정과 확률예측

조건부 모형의 CRPS는 6.85 kW로 기존 BAT 6.99보다 작다. 원시 위험확률의 평균 Brier는 0.09987로 기존 0.10033과 가깝고 공통 정규 BAT의 0.09008보다 크다. 피크 시점 ± 30 분 적중률은 기존 25.5%에서 19.6%로 낮아졌다. 최




그림 2: 전체와 상태별 일 피크 오차. 집단별 표본 수와 기준선 순위가 다르다.

지표	공통 정규	조건부 정규
슬롯 CRPS (kW)	7.43	6.85
슬롯 90% 포함률	97.4%	99.1%
일 피크 90% 포함률	67.3%	90.2%
일 피크 90% 평균 폭 (kW)	49.92	48.77
가동일 피크 90% 포함률	92.8%	86.5%
가동일 피크 90% 평균 폭 (kW)	52.53	62.65
고피크 90% 포함률	100%	100%

표 4: 세 시드별 구간 지표의 평균. 포함률은 폭과 함께 비교한다.

대값의 크기를 개선한 것과 시점 또는 사건 확률을 개선한 것은 별개다.

전체 피크의 포함률은 명목 수준에 가까워졌지만 가동일 피크 구간은 더 넓어졌다. 고피크 13일은 두 정규 모형 모두 100% 포함하므로 이 소표본만으로 꼬리 분포가 정확하다고 말하기 어렵다. 조건부 슬롯의 90% 구간 포함률 99.1%는 주변분포가 과도하게 넓다는 신호다. 하루 수준의 상태 구분만으로는 가동일 내부의 조용한 구간을 충분히 설명하지 못한다.

6.5 사후 진단과 분포의 물리적 한계

기본 split- $\hat{R}$ 의 잡음 모수 최댓값은 조건부 1.017, 공통 정규 1.024였다. 그러나 어텐션과 이득을 포함하면 각각 1.308과 2.303으로, 사전에 둔 1.05 기준을 넘는다. 진단은 세 시드와 내부·외부 적합을 대상으로 한 고전적인 split-chain 분산비다. rank-normalized/folded 진단이나 tail ESS는 계산하지 않았으며, 기본곡선의 모든 좌표에 대한 수렴도 확인하지 않았다. 따라서 전체 사후분포의 충분한 수렴을 주장할 수 없다.

그림 4의 하단은 상태별 잡음 표본을 시드별로 보여준다. 조건부 모형의 시드별 전체 피크 MAE는 9.151–9.174, 고피크 MAE는 4.266–4.507 kW였다. 예측 점수의 안정성과 모수 사후분포의 수렴은 서로 다른 성질이다. 특히

기본곡선·기준곡선·생산 전달항이 유사한 수준 변화를 설명할 수 있어, 예측이 비슷해도 개별 모수의 식별은 약할 수 있다.

식 (12) 적용 전 음수 경로도 남는다. 유효 관측 슬롯의 음수 비율을 날짜별로 구해 평균하면 비가동 유형에서는 약 0.020%지만 1–12시간 가동 유형에서는 14.71%다. 이러한 표본을 0으로 보내므로 예측분포에 0의 질량이 생긴다. 학습에서 0은 계측 결손으로 제외했고 양수 전력의 최솟값은 19 kW였기 때문에, 이 질량을 실제 무부하 확률로 해석할 수 없다. 다음 개선은 가동일 내부의 생산/무생산에 따른 혁신 분산과 양수 지지 분포를 검토하는 것이며 아직 실행하지 않았다.

7 계획 오차와 시간대 이동의 보조 분석

이 절의 실험은 기존 Laplace BAT와 튜닝 LightGBM으로 수행한 선행 보강 분석이다. 새 조건부 정규 BAT로 다시 실행하지 않았으므로 앞 절의 피크 개선을 시간대 이동의 개선으로 연결하지 않는다. 또한 실제 공장에서 계획을 변경한 결과가 아니라, 입력 변화와 모델 기반 반사실 계산의 민감도를 살펴보는 분석이다.

7.1 생산계획 입력 오차

학습 자료와 실제 전력 목표를 고정한 채 예측일의 계획 입력만 바꾸었다. 생산량 오차는

$$q_{d,h}^{\text{input}} = q_{d,h} \exp(\sigma Z_{d,h} - \sigma^2/2), \quad Z_{d,h} \sim \mathcal{N}(0, 1) \quad (14)$$

로 두어 곱셈 오차의 평균이 1이 되게 했다. $\sigma = 0.05, 0.1, 0.2$ 마다 날짜별 10회 반복하고, 반복 점수는 날짜 안에서 먼저 평균하였다. 0인 시각은 그대로 유지된다. 시간 오차는 전체 계획을 한 시간 앞이나 뒤로 옮기되 날짜 밖으로 나가는 생산을 00시 또는 23시에 남겨 총량을 보존했다. 이는 계획 입력의 오기입 검사이며 변경 후 실제 전력을 생성한 실험이 아니다.

기존 BAT의 MAE는 생산량 $\sigma = 0.2$ 에서 0.03%, 한 시간 이른 계획에서는 5.68% 증가했다. 로그 채널과 유형별 기본곡선을 함께 사용하는 모델이 생산량의 작은 변화보




그림 3: 비가동일, 고피크가 아닌 가동일, 고피크일의 예측 예시. 각 집단의 피크 평가 가능일 중 조건부 모델 시드 0의 일 MAE가 집단 중앙값에 가장 가까운 날짜를 선택한다. 구간은 조건부 경로의 분위수다.

입력 조건	기존 BAT MAE	튜닝 M2 MAE
오차 없음	7.820	11.048
생산량 $\sigma = 0.05$	7.820	11.049
생산량 $\sigma = 0.10$	7.821	11.049
생산량 $\sigma = 0.20$	7.823	11.056
1시간 이른 계획	8.264	11.915
1시간 늦은 계획	7.878	11.741

표 5: 기존 모형의 계획 입력 오차 민감도(kW). 동일 53일의 5,016개 관측 슬롯을 사용하며 반복으로 평가 표본수를 늘리지 않는다.

다 가동 시작 변화에 민감하다는 설명과 부합한다. 그러나 계획 취소·설비 고장·제품 전환은 가동 여부 자체를 바꿀 수 있으므로 이 결과로 그러한 상황의 강건성을 주장하지 않는다.

7.2 시간대 이동과 정오 제약

후보 계획은 하루 생산 총량을 보존하고 날짜 경계를 넘지 않는다. 학습기간의 유형별 시작 시각 빈도에 Dirichlet 평활화를 적용하고, 주간·야간의 양수 생산량을 각각 Gamma 적률로 근사했다. 블록 이동은 새로운 시작 시각의 사후예측확률이 5% 이상인 경우에만, 인접 시간 이동은 더 낮은 요금 시간대이며 이동 후 생산량이 해당 구간의 Gamma 95분위 이내인 경우에만 허용했다. 이 조건들은 과거 관측 지지 범위를 이용한 제약이며 설비 능력과 작업 순서를 직접 측정된 제약은 아니다.

이 보조 시뮬레이션의 실행 오차는 $q_h^{\text{exec}} = q'_h \exp(\sigma Z_h)$ 를 사용했다. 입력 오기입 실험의 평균 1 보정과 달리 중앙값이 1인 로그정규 오차이며, 실현 생산 총량은 표본마다 달라질 수 있다. 원계획과 후보계획의 오차는 같은 분포에서 독립적으로 생성한다. 후보 식별자에 난수를 고정하여 정오 제약으로 다른 후보를 제거해도 남은 후보의 통계는 유지한다.

사후 모수와 실행 오차 표본에서 계산한 평균구조 곡




그림 4: 조건부 BAT의 f_4 외부 적합. 위: 가동유형 2 어텐션의 시드별 사후평균. 아래: 비가동·가동의 날짜 효과와 혁신 표준편차(kW), 자기상관. 서로 다른 fold의 표본을 하나의 사후분포로 합치지 않는다.

선을 $f_t^{(s)}(q)$ 라 하고, 중간·최대부하 시간대를 $\mathcal{D}$ 라 하자. 기존 구현의 권고 조건은

$$\frac{1}{S} \sum_{s=1}^S \mathbf{1} \left[\max_{t \in \mathcal{D}} f_t^{(s)}(q') < \max_{t \in \mathcal{D}} f_t^{(s)}(q) \right] \geq 0.95 \quad (15)$$

이다. 이 곡선에는 식 (12)의 새로운 날짜 효과와 AR 잔차를 추가하지 않는다. 따라서 식 (15)은 완전한 미래 관측 경로에 대한 성공확률이 아니라, 기존 평균구조와 실행 오차 아래의 모형 기반 판단이다. 여러 후보가 통과하면 전력량요금과 수요요금 일할 대응치 변화의 표본 평균이 가장 작은 계획을 선택했다.

정오 제약은 $q'_{12} \leq q_{12}$ 로 적용하여 12시의 추가 생산만 금지했다. 정오 완전 비가동을 강제한 것은 아니다. 후보가 없는 1일을 무조치로 포함하여 허용·금지 조건 모두 가동일 39일을 분모로 사용했다. 이 39일은 실제 피크 평균 가능한 37개 가동일과 목적 및 마스크가 다르다.

정오 제약 이후 권고일의 피크 감소는 작아졌지만 전체 가동일 평균 전력량요금 감소의 약 88%가 남았다. 선택된 계획은 10시에서 09시 이동 12일, 16시에서 17시 이동 6일, 블록 전체를 한 시간 앞당기는 이동 1일이었다. 같은

$\sigma = 0.1$	정오 증가 허용	증가 금지
대상 / 권고일	39 / 20	39 / 19
권고일 피크 감소 중앙값 (kW)	3.38	2.11
권고일 전력량요금 중앙값 (원)	-4,433	-4,399
전체일 전력량요금 평균 (원/일)	-2,150	-1,891

표 6: 기존 BAT의 정오 제약 민감도. 음의 비용 변화는 모델상 감소를 뜻한다. 권고하지 않은 날은 변화 0으로 집계하며 실제 청구액 절감이 아니다.

날 생산 총량의 보존이나 요금 시간대 회피만으로 현장 실행 가능성이 보장되지는 않는다. 실제 기본요금은 월 최대수요 및 과거 피크의 래치 바닥과 관계되므로 수요요금 일할 대응치와 구분해야 한다. 신규 조건부 모형에서는 의사결정 계산을 다시 검증해야 한다.

8 논의와 한계

조건부 구조의 가장 분명한 이점은 서로 다른 상태에 공통 잡음을 적용했을 때 발생하는 피크 왜곡을 줄인다는 데




그림 5: 슬롯과 일 피크의 90% 구간 평가. 같은 모형에서도 주변 슬롯과 최대값 분포의 보정은 다르다. 피크 구간 비교는 저장된 경로 분위수가 있는 두 정규 모형을 사용한다.

있다. 특히 비가동일과 고피크일에서 개선이 나타났지만, 상태별 기초 패턴을 재사용하는 B0-kind는 전체 피크에서 더 정확했다. 실무에서는 복잡한 분포 모델의 필요성을 사전에 가정하기보다, 동일 가동유형 기준선을 운영 기준으로 두고 확률 정보나 계획 변화 평가에서 추가 가치가 있는지 확인하는 편이 타당하다.

생산실적을 계획으로 간주하므로 실제 계획 오차의 분포를 알 수 없고, 사후에 분류한 고피크일의 좋은 점수가 사전 정보 성능을 보장하지 않는다. 관측일은 짧고 단일 공장에 한정되며, 복사일 제외 후 유효 표본은 더 작다. 이미 확인한 검증 기간의 반복 실험이므로 모형 선택 편향이 남고, 신규 조건부 모델의 독립 시험 결과는 없다. 모형·시드 반복 수가 이러한 자료 한계를 보완하지는 않는다.

계산적 한계도 성능 해석에 포함해야 한다. 일부 어텐션의 수렴 실패, 과도한 슬롯 구간 폭, 음수 경로 절단은 확률 경로의 신뢰도를 제한한다. 조건부 모형이 높은 피크에서 개선되었다는 사실만으로 꼬리 위험이나 인과 전달구조를 검증했다고 결론 내릴 수 없다. 조건부 전달항 제거 비교, 고정 커널 비교, 더 세밀한 상태별 잔차와 별도 기간의 검증이 필요하다.

마지막으로 생산 시각을 바꾸면 본 자료에 없는 설비 순서·작업자·제품 구성의 변화가 생길 수 있다. 과거 관측 지지 범위와 생산 총량 보존은 필요한 제약이지만 충분한 현장 타당성 조건은 아니다. 실제 적용에서는 계획 발행 로그, 변경 후 계획과 작업 제약을 확보하고 요금 효과는 월 최대수요 및 래칭 규정까지 포함해 별도로 평가해야 한다.

9 결론

본 연구는 조건부 정규 BAT를 구현하였다. 이 모형은 희소 어텐션 전달 평균식에 가동 상태별 날짜 효과와 정상 AR 잔차를 결합한다. 결국 관측의 전이분포와 가중 공동우도를 명시하고 동일 검증 표본에서 점예측·확률예측·피크를 함께 비교하였다. 비가동일과 높은 피크에서는 조건화의 가능성이 보였지만 전체 피크에서는 단순 기준선이 우위였고 가동일 전체 오차와 구간 폭 및 수렴에도

한계가 있었다. 조건부 BAT는 특정 조건의 피크 분포를 개선하는 탐색적 모형이며 어텐션 유지·제거와 현장 적용은 추가 비교 및 독립 검증에 따라 결정해야 한다.

재현 자료

학습·예측은 `gmst/conditional_bat.py`, 실험은 `gmst/run_conditional.py`, 재평가는 `gmst/rescore.py`에 구현하였다. 그림은 `gmst/paper_figures.py`로 저장된 예측에서 PDF로 생성한다. `notebooks/01_conditional_bat.ipynb`는 수식, 마스크, 상태별 지표, 수렴 진단과 그림을 재현한다. 기본 노트북 실행은 모형을 재학습하거나 9월 목표를 열지 않는다. 학습 당시 소스 해시와 후속 보고서·평가 코드의 해시를 구분하여 보존한다.

참고문헌

- Berk, K.; Hoffmann, A.; and Müller, A. 2018. Probabilistic Forecasting of Industrial Electricity Load with Regime Switching Behavior. *International Journal of Forecasting*, 34(2): 147–162.
- Gneiting, T.; and Raftery, A. E. 2007. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477): 359–378.
- Ke, G.; Meng, Q.; Finley, T.; Wang, T.; Chen, W.; Ma, W.; Ye, Q.; and Liu, T.-Y. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems*, volume 30.
- Martins, A. F. T.; and Astudillo, R. F. 2016. From Softmax to Sparsemax: A Sparse Model of Attention and Multi-Label Classification. In *Proceedings of the 33rd International Conference on Machine Learning*, 1614–1623.
- Platt, J. C. 1999. Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Like-

likelihood Methods. In *Advances in Large Margin Classifiers*, 61–74. MIT Press.

Rigby, R. A.; and Stasinopoulos, D. M. 2005. Generalized Additive Models for Location, Scale and Shape. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 54(3): 507–554.

Rue, H.; and Held, L. 2005. *Gaussian Markov Random Fields: Theory and Applications*. Chapman and Hall/CRC.

Welty, L. J.; Peng, R. D.; Zeger, S. L.; and Dominici, F. 2009. Bayesian Distributed Lag Models: Estimating Effects of Particulate Matter Air Pollution on Daily Mortality. *Biometrics*, 65(1): 282–291.

Zeng, A.; Chen, M.; Zhang, L.; and Xu, Q. 2023. Are Transformers Effective for Time Series Forecasting? In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, 11121–11128.