

일반국민/대학(원)생 부문

제6회 K-인공지능 제조데이터 분석 경진대회 보고서

프로젝트명	생산계획 기반 조건부 베이지안 전달모형(C-BAT)을 이용한 제조공장 전력 예측과 최대피크 위험조건 분석
팀명	_____
내용요약	제조공장의 하루 96개 15분 슬롯 전력을 매일 00:00에 그날의 시간별 생산계획, 달력, 전날까지의 관측 전력만으로 예측하고, 최대피크 위험과 요금에 영향을 주는 날을 가려내는 방법을 제안한다. 제안 모형 C-BAT은 가동유형별 기본곡선, 과거 기준일 곡선, 생산계획의 전달항, 가동 여부에 따라 달라지는 잡음을 베이지안으로 함께 추정하고, 예측 경로에서 피크 분포와 초과확률을 계산한다. 전력이 소수점까지 같은 복사일 122일을 찾아 목표에서 제외하고, 무작위 교차검증이 성능을 부풀린다는 누수 진단을 근거로 시간순 검증을 설계하였다. 개발 구간(2021-07-07-08-31)에서 C-BAT의 슬롯 MAE는 8.50 kW로 튜닝한 LightGBM(11.05 kW)보다 작았고, 고피크일 피크 MAE는 4.37 kW로 LightGBM(18.27 kW)의 4분의 1 수준이었다. 9월 시험 14일에는 LightGBM이 더 정확했으며, 이 구간에 고피크일이 없었다는 점과 함께 그대로 보고한다. 현장 활용으로는 월 최대수요를 갱신할 위험이 있는 날만 경보하는 규칙을 제안하였고, 과거 자료 백테스트에서 기간 중 유일한 갱신일을 사전에 잡아냈다.

상기 본인(팀)은 위의 내용과 같이 제6회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다.

2026년 10월 일

팀장 : _____ (서명)

팀원 : _____ (서명)

팀원 : _____ (서명)

(사)중소기업기술혁신협회 귀중

평가 항목과 보고서 구성

보고서의 장은 공식 평가 항목과 아래와 같이 대응한다.

평가 항목 (배점)	보고서 위치	주요 내용
1. 데이터 이해 및 진단 (15)	3장	변수, 전처리 구조, 복사일·결측, 누수 진단
2. AI 예측모델 개발 및 성능평가 (40)	2장, 4.1–4.2절, 4.6–4.7절	방법론, 비교 모델, 성능, 절제, 9월 시험, 최
3. 영향요인 및 오류분석 (15)	4.3–4.5절	오차·피크 발생 조건, 미탐지·오경보, 입력
4. 현장 활용방안 (10)	5장	월 최대 갱신 경보, 백테스트, 현장 검증
5. 창의성 및 차별성 (10)	6.1절	선행 방법 대비 차별점과 효과
6. 코드 및 재현성 (10)	부록 A	한 줄 실행, 재현 명령, 누수 점검

목차

평가 항목과 보고서 구성	1
1 서론	4
1.1 동기	4
1.2 문헌연구	4
1.3 기여	5
2 방법론	6
2.1 문제 정의와 표기	6
2.2 모델 구조	7
2.3 베이지안 추정	9
2.4 예측 경로와 피크 위험	9
2.5 월 최대 갱신 경보 규칙	10
3 데이터 분석	10
3.1 데이터와 변수	10
3.2 전처리 구조	11
3.3 가동유형과 생산-전력 관계	12
3.4 누수 진단과 검증 설계	13
4 결과 및 오류분석	14
4.1 실험 설정과 성능 비교	14
4.2 절제와 불확실성	15
4.3 오차와 피크가 발생하는 조건	17
4.4 경보의 미탐지·오경보 조건	19
4.5 생산계획 입력 오차의 영향	20
4.6 9월 시험	20
4.7 확장 실험과 최종 모델 선택	21
5 현장 활용방안	22
5.1 요금을 정하는 날과 경보 규칙	22
5.2 백테스트와 경보일 조치	23
5.3 모형 반사실을 쓰지 않는 이유와 현장 검증	24
6 차별성과 결론	25
6.1 창의성 및 차별성	25
6.2 한계와 결론	25
A 코드 구성 및 재현성	29
A.1 한 명령 실행과 환경 고정	29

A.2 코드 구성	29
A.3 결과와 명령의 대응	29
A.4 자료 분할과 9월 봉인	30
A.5 누수 점검	30
A.6 반복 설정과 검사	31
A.7 사전 등록 기록	31
B 모형 세부 사항	32
C 경진대회 만족도 조사 완료 화면	33

1 서론

1.1 동기

제조공장의 전력 관리는 하루 평균보다 최대수요전력을 먼저 봐야 한다. 공모 과제 ⑤는 공장 전력이 설비 동시 가동, 생산량 변화, 제품 전환, 교대 시간, 계절 요인에 따라 달라지고, 최대수요전력이 전력비용과 생산 안정성에 영향을 준다고 설명한다. 평균 전력은 생산량을 따라 완만하게 움직이지만 최대수요전력은 여러 설비가 같은 15분 안에 겹칠 때 한 번에 올라간다. 부하가 한 시간대에 몰리면 수전 설비의 여유가 줄고 설비 운전도 불안정해진다.

산업용 전기요금 구조에서는 단 하루가 한 달, 나아가 이후 여러 달의 기본요금을 정한다. 기본요금은 요금 시간대(일요일·공휴일을 제외한 09-23시의 중간·최대부하 시간대)의 월 최대수요 전력으로 매겨지고, 12·1·2·7·8·9월의 최대수요전력은 이후 달의 하한(래치)으로도 쓰인다. 본 보고서가 분석한 공장에서는 2021년 7월 19일이 이런 날이었다. 이날 요금 시간대 최대는 222 kW로, 그 전까지의 기준선 206 kW를 16 kW 넘었다. 기본요금 8,320원/kW·월을 적용하면 그 달에만 133,120원이 더 붙고, 7월은 래치 적용월이므로 이 값은 이후 달의 하한에도 남을 수 있다. 검증 구간(7월 7일-8월 31일)에서 요금 시간대가 있는 44일 가운데 월 최대를 새로 쓴 날은 이 하루뿐이었다.

그래서 예측은 운영 결정이 가능한 시점에, 결정에 쓰는 정보로 내야 한다. 본 보고서의 예측은 매일 00:00에 발행한다. 입력은 당일의 시간별 생산계획, 요일과 공휴일 같은 달력 정보, 전날까지의 전력 관측이며, 출력은 당일 96개 15분 슬롯의 전력 분포다. 생산계획은 공장이 전날에 이미 알고 있고 바꿀 수도 있는 입력이다. 이 정보로 전력을 예측하면 결과를 계획 점검과 연결할 수 있다.

실무에서 필요한 답은 평균 정확도만이 아니다. 운영자는 오늘이 최대 피크 위험이 높은 날인지, 그렇다면 무엇을 점검해야 하는지를 알고 싶어 한다. 슬롯별 오차가 작아도 고피크일의 최댓값을 크게 낮춰 잡는 모형은 요금 관점에서 쓸모가 적다. 반대로 매일 경보를 내면 현장은 곧 경보를 무시한다. 본 보고서는 15분 곡선의 정확도, 일 피크의 분포, 월 최대 갱신 위험을 한 모형에서 함께 산출하고 각각을 따로 채점한다.

1.2 문헌연구

공장 부하 예측과 생산 정보. 생산 정보를 입력하면 공장 전력 예측이 좋아진다는 근거는 쌓였지만, 시간별 생산계획을 15분 전력의 확률분포로 옮긴 연구는 드물다. Walther와 Weigold의 체계적 문헌검토는 제조업 전력 연구 72편 가운데 공장 단위 예측을 다룬 논문이 3편뿐임을 보였다 [1]. 제지 공장 연구에서는 생산관리 정보를 넣자 MAPE가 평균 18.3% 개선되었다 [2]. Trenz et al. [3]은 생산계획과 기상 예보로 15분 전력을 예측하는 도구를 제시했다. 국내 대형 제조공장을 다룬 Kim et al. [4]은 일 작업량으로 일 피크를 먼저 회귀한 뒤 이를 조건으로 시간별 피크 계열을 생성했는데, 시간별 계획은 실무에서 드물다고 보고 일 단위 작업량만 썼다. 조선소 사례 [5]는 공정 지표·달력·기상을 입력으로 일 피크를 예측하는 12개 모형을 비교하고, 래치 요금 아래서는 하루의 높은 피크가 연간 비용을 좌우한다고 지적했다. Berk et al. [6]은 산업 부하의 가동과 정지를 레짐 전환으로 보고 확률 예측을 했다. 이 연구들은 대부분 점예측을 MAPE·MAE로 평가하거나 일 단위 피크만 다룬다.

확률 예측과 피크 위험. 확률 예측의 평가 체계는 자리를 잡았지만 하루 최댓값은 시점별 분위수에서 바로 얻을 수 없다. Hong and Fan [7]은 확률적 부하 예측의 입력, 모형, 평가를 정리했고, GEFCOM2014는 분위수와 pinball loss를 표준 평가로 정착시켰다 [8]. pinball loss는 분위수 회귀 [9]의 점검 함수이며, CRPS와 함께 엄밀히 적절한 점수 규칙에 속한다 [10]. 피크를 확률로 다룬 연구는 두 갈래로 나뉜다. 하나는 피크를 직접 예측하는 방식이다. Hyndman and Fan [11]은 연간 피크의 밀도와 초과확률을 제시했고, Amara-Ouali et al. [12]은 고해상도와 저해상도 정보를 함께 써서 일 피크의 크기와 시각을 예측했다. Gilbert et al. [13]은 일반 예측이 지나치게 매끄러워 피크를 낮춰 잡는다는 점을 지적하고 일 피크 예측을 30분 예측과 융합해 피크 시간대 CRPS를 개선했다. 다른 하나는 하루 전체 경로의 공동분포를 표집한 뒤 그 최댓값을 취하는 방식이다. 이 방식은 곡선, 피크, 초과확률을 하나의 분포에서 일관되게 얻지만 경로 잡음의 크기가 맞지 않으면 피크가 한쪽으로 치우친다. 본 보고서는 경로 방식을 택하고, 이 치우침을 가동 상태별 잡음으로 다룬다.

베이지안 평활 모형과 유사일. 곡선의 형태, 입력의 시차 효과, 상태에 따른 분산은 각각 확립된 도구가 있지만 한 사후분포로 묶여 쓰인 예는 찾지 못했다. RW2 사전분포는 가우스 마르코프 확률장의 대표 사례로 곡선을 매끄럽게 추정한다 [14]. 베이지안 분포시차모형은 시차 계수에 평활 제약을 두어 입력이 여러 시차에 걸쳐 전달되는 구조를 추정한다 [15]. GAMLSS는 분산 같은 분포 모수를 공변량의 함수로 둔다 [16]. 과거 사례를 빌리는 쪽에서는 유사일(analog) 예측이 오래 쓰였고, McDermott and Wikle [17]은 이를 베이지안 모형으로 정식화해 예측 불확실성을 정량화했다. 학습형 어텐션도 과거 관측과 미래에 알려진 입력을 결합하는 방법이다 [18]. sparsemax는 가중치를 정확히 0으로 만들 수 있어 소수의 참조만 남기는 희소한 어텐션을 준다 [19]. 그러나 학습형 가중치는 작은 공장 자료에서 불안정하다. 본 보고서는 sparsemax를 고정된 국소 커널로 써서 분포시차 전달함수처럼 해석한다.

수요요금과 생산 일정. 피크 저감 스케줄링 연구는 설비 전력을 알려진 값으로 두므로 예측 오차가 결정에 미치는 영향을 다루지 않는다. Gahm et al. [20]은 에너지 효율 스케줄링 연구를 정리했고, Fang et al. [21]은 피크 전력을 목적함수에 넣은 flow shop 모형을 제시했다. Shrouf et al. [22]은 시간대별 요금(TOU)에서 설비 가동 시점을 최적화했고, Shoreh et al. [23]은 산업 수요반응의 잠재력과 도입 장벽을 조사했다. 이 흐름은 계획을 바꾸면 피크가 얼마나 줄지를 결정론적으로 계산한다. 예측 연구는 반대로 조치 단계까지 가지 않는다.

네 갈래를 합치면 공백이 드러난다. 시간별 생산계획을 조건으로 15분 전력의 공동 경로를 만들고, 그 경로에서 일 피크 분포와 월 최대 갱신 위험을 함께 산출해 요금 규칙에 맞춰 채점한 공장 단위 연구는 찾지 못했다. 본 보고서는 이 공백을 다룬다.

1.3 기여

첫째, 생산계획을 조건으로 한 베이지안 전달모형 C-BAT를 제안하고 고피크일 피크 오차를 크게 줄였다. C-BAT는 가동유형별 기준 곡선, 최근 기준일, 생산계획의 양(+)의 전달항을 결합하고 잡음의 크기를 가동 상태에 따라 다르게 둔다. 시간순 검증 구간 f1-f4(53일, 피크 평가 51일)에서 고피크일 13일의 피크 MAE는 C-BAT 4.37 kW로, 튜닝한 LightGBM [24]의 18.27 kW와 기존

BAT의 12.47 kW보다 작았다. 날짜 단위 짝지는 부트스트랩에서 LightGBM과의 차이는 -13.90 kW(95% 구간 $-19.02 - -9.86$)였다. 전체 피크 MAE는 기준일 복사 기준선(B0_kind, 6.67 kW)이 C-BAT(8.93 kW)보다 낮았다는 점도 함께 밝힌다.

둘째, 사후 경로로 월 최대 갱신 위험을 계산하는 경보를 만들고 과거 날짜 백테스트로 채점했다. 경보는 요금 시간대 경로 최댓값이 그날까지의 기준선을 넘는 정도로 기대 초과 기본요금을 계산하고, 이 값이 3만 원 이상이면 점검을 권한다. 검증 구간의 유일한 갱신일인 7월 19일에 C-BAT는 갱신 확률 0.58, 기대 초과 비용 122,919원을 내어 경보했고, B0_kind는 195 kW를 예측해 놓쳤다. 주 규칙의 경보는 44일 중 10회였고 그중 9회는 오경보였다. 갱신일이 하루뿐이므로 이 결과는 성능 추정이 아니라 사례로 제시한다.

셋째, 자료의 복사일과 평가 누수를 먼저 진단하고 채택 규칙을 결과 확인 전에 고정했다. 첫 검증 구간의 학습기간 186일 가운데 121일이 전력 곡선이 복사된 날이었다. 복사일이 섞인 자료에서 날짜를 무작위로 나누면 LightGBM의 MAE가 14.91 kW로, 복사 사건 단위로 떼어 낸 평가의 16.64 kW보다 약 10% 좋게 보였다 [25, 26]. 그래서 모든 비교는 복사일을 뺀 시간순 분할로 했다. 확장 실험(계획 기반 기준일, 어텐션 기준일, 피크 계층, 앙상블)은 사전 등록한 규칙으로 판정했고 채택된 것은 없다. 9월 1-14일 구간에서는 C-BAT의 슬롯 MAE가 7.18 kW, 피크 MAE가 8.93 kW로 LightGBM 기반 M2(6.60 kW, 5.53 kW)보다 나뉘었다. 이 구간은 이전 개발 중에 한 번 열린 적이 있어 모형 선택 근거로 쓰지 않았지만, 결과는 그대로 보고한다.

넷째, 현재 생산계획에는 고평크일을 평범한 가동일과 가르는 정보가 거의 없다는 근거를 여러 모형에서 얻었다. 계획 기반 기준일은 슬롯 MAE를 0.87 kW 낮췄지만 가동일 피크 과대예측을 바꾸지 못했다. 기준일 피크를 가동유형별로 재보정한 피크 계층은 두 설계 모두 고평크일을 20 kW 이상 낮춰 잡았다. C-BAT 경보가 놓친 고평크일도 모두 7월의 가장 긴 가동유형에 몰렸다. 이 결과는 피크 예측을 개선하려면 모형보다 설비별 가동 일정이나 제품 전환 기록 같은 자료를 먼저 모아야 함을 가리킨다.

2장은 C-BAT의 구조와 경로 기반 피크 위험 계산을 설명한다. 3장은 자료의 복사일, 결측, 피크 발생 조건을 분석한다. 4장은 비교 모형과의 결과와 오류 조건을 제시한다. 5장은 월 최대 갱신 경보의 현장 활용방안을, 6장은 차별성과 결론을 다룬다. 부록 A는 재현 절차를 담는다.

2 방법론

이 장은 최종 모델 C-BAT의 구조, 추정, 예측 산출 방식을 정의한다. 자료 전처리는 3장, 검증 결과와 비교 모델은 4장에서 다룬다. 이 장에서 정한 기호는 보고서 전체에서 같은 뜻으로 쓴다.

2.1 문제 정의와 표기

예측 과제는 예측일 d 의 00:00에 그날 15분 슬롯 전력 $y_{d,t}$, $t = 1, \dots, 96$ 을 한꺼번에 내는 것이다. 00:00에 쓸 수 있는 정보는 그날의 시간별 생산계획 $q_{d,h}$ ($h = 0, \dots, 23$), 달력 정보(요일, 날짜유형), 그리고 $d - 1$ 일까지 관측된 전력이다. 예측일 당일의 전력은 한 슬롯도 쓰지 않는다.

모델은 점예측 하나가 아니라 하루 전체 전력 경로의 예측분포를 낸다. 이 분포에서 세 가지 산출물을 얻는다. 첫째는 슬롯별 분위수와 점예측이다. 둘째는 일 피크 $M_d = \max_t y_{d,t}$ 의 분포다. 셋째는 피크 초과확률 $P(M_d > C)$ 이며, C 는 학습 구간에서 정한 피크 기준이다. 슬롯마다 따로 만

든 분위수로는 일 피크 분포를 얻을 수 없으므로, 하루 곡선 전체를 함께 표집하는 구조가 필요하다. 표 1은 이 장에서 쓰는 기호다.

표 1: 주요 기호.

기호	뜻
d	날짜(예측일)
$t = 1, \dots, 96$	15분 슬롯
$h = 0, \dots, 23$	생산계획의 시간
$y_{d,t}$	슬롯 전력(kW)
$q_{d,h}$	시간별 생산계획량, $q_{\max}$ 는 학습 구간 최댓값
$k \in \{0, 1, 2, 3\}$	가동유형(계획 생산시간 0 / 1-12 / 13-19 / 20시간 이상)
$g \in \{\text{비가동}, \text{가동}\}$	잠음 상태($k = 0$ 이면 비가동, $k \geq 1$ 이면 가동)
$\mu_{k,t}$	가동유형별 기본곡선
$r_{d,t}, \gamma_k$	기준일 곡선과 그 계수
$x_c(q), c \in \{\text{on}, \text{log}\}$	생산 채널(생산 여부, 정규화 로그 생산량)
$w_{c,k} = e^{\omega_{c,k}}$	채널별 생산 이득(양수)
$\alpha_{t,h}$	시간 계획을 슬롯으로 옮기는 커널 가중치
$u_d, \sigma_{u,g}$	날짜 효과와 그 표준편차
$e_{d,t}, \rho_g, \sigma_{\eta,g}$	슬롯 AR(1) 잡음, 자기상관, 혁신 표준편차
ω_d	반감기 시간 가중치
M_d	일 피크 $\max_t y_{d,t}$
C_{50}, C_{75}, C_{90}	학습 구간 가동일 피크의 50·75·90% 분위수
B_d	월 최대 경보의 기준선(00:00에 알려진 요금 적용 최대)

2.2 모델 구조

C-BAT는 슬롯 전력을 평균 곡선 세 항과 변동 두 항의 합으로 둔다.

$$y_{d,t} = \underbrace{\mu_{k,t}}_{\text{기본곡선}} + \underbrace{\gamma_k r_{d,t}}_{\text{기준일}} + \underbrace{\sum_{c \in \{\text{on}, \text{log}\}} w_{c,k} \sum_{h=0}^{23} \alpha_{t,h} x_c(q_{d,h})}_{\text{생산 전달항}} + \underbrace{u_d}_{\text{날짜 효과}} + \underbrace{e_{d,t}}_{\text{슬롯 잡음}} \quad (1)$$

여기서 k 는 예측일 d 의 가동유형이다. 앞의 세 항은 생산계획과 최근 운전 상태가 정하는 평균 곡선이고 뒤의 두 항은 그 주변의 변동이다. 이름의 C(conditional)는 변동의 크기와 지속성을 가동 상태별로 따로 두는 데서 붙었다. 추정엔 학습 구간 전력 표준편차로 나눈 표준화 단위에서 하고 예측 경로를 만든 뒤 kW로 되돌린다.

가동유형 k 는 그날 생산계획만으로 정해지므로 00:00에 알 수 있다. 계획량이 양수인 시간 수가 0이면 $k = 0$ (비가동), 1-12시간이면 $k = 1$, 13-19시간이면 $k = 2$, 20시간 이상이면 $k = 3$ 이다. 기본곡선, 기준일 계수, 생산 이득은 모두 가동유형마다 따로 둔다. 운전 시간이 다른 날은 하루 곡선의 모양 자체가 다르기 때문이다.

기본곡선 $\mu_{k,t}$ 는 가동유형별 하루 평균 모양을 맡는다. 96개 값에 순환 2차 확률보행(RW2) 사전분포 [14]를 둔다. 인접 슬롯의 이차 차분 $\mu_{k,t+1} - 2\mu_{k,t} + \mu_{k,t-1}$ 에 벌점을 주고 슬롯 96과 슬롯

1을 이어 자정 전후도 매끄럽게 잇는다. 평활 강도 τ_k 도 가동유형마다 추정하므로, 자료가 적은 유형에서는 곡선이 더 매끄럽게 수축된다.

기준일 곡선 $r_{d,t}$ 는 최근 공장 상태를 평균에 들인다. 기준일은 예측일 이전 28일 안에서 가동 여부와 날짜유형(평일·토요일·일요일)이 모두 같은 완전 관측일(96슬롯 모두 관측) 가운데 가장 최근 날이다. 이 규칙은 기준선 B0'와 같다. 28일 안에 그런 날이 없으면 가동 여부만 같은 가장 최근 완전 관측일을 쓰고 그것도 없으면 학습 구간의 해당 가동유형 평균 곡선을 쓴다. 계수 γ_k 는 기준일 곡선을 얼마나 따를지 정한다. 기본곡선이 긴 기간의 평균 모양을 맡는다면, 기준일 항은 계절에 따라 움직이는 최근 수준을 따라간다.

생산 전달항은 시간별 생산계획을 15분 슬롯의 전력 증가분으로 옮긴다. 계획량은 두 채널로 바꾼다.

$$x_{\text{on}}(q) = \mathbf{1}[q > 0], \quad x_{\text{log}}(q) = \frac{\log(1+q)}{\log(1+q_{\max})}. \quad (2)$$

첫 채널은 라인이 도는지를, 둘째 채널은 생산량의 크기를 나타낸다. 이득은 $w_{c,k} = \exp(\omega_{c,k})$ 로 두어 양수로 제약한다. 두 채널 모두 q 에 대해 줄지 않으므로, 계획 생산량이 늘면 예측 평균 전력도 줄지 않는다. 비가동일($k=0$)에는 생산이 없으므로 전달항을 두지 않는다($w_{c,0} = 0$).

시간 계획을 슬롯으로 옮기는 가중치 $\alpha_{t,h}$ 는 고정된 sparsemax 커널이다.

$$\alpha_{t,\cdot} = \text{sparsemax} \left(-\frac{|\Delta_{t,h} - c|^\beta}{\sigma} \right)_{h=0,\dots,23}, \quad \Delta_{t,h} = \frac{t - 4h - 2.5}{4}, \quad (\sigma, \beta, c) = (1.5, 2, 0). \quad (3)$$

$\Delta_{t,h}$ 는 슬롯 t 의 중앙 시각과 시각 h 의 중앙 시각 사이의 차이(시간 단위)다. sparsemax [19]는 점수 벡터 z 를 확률 단체에 유클리드 사영한 $\text{sparsemax}(z)_h = \max(z_h - \tau(z), 0)$ 이다. 가중치의 합은 1이고 먼 시각의 가중치는 정확히 0이 된다. 척도 $\sigma = 1.5$, 형상 $\beta = 2$, 시차 $c = 0$ 은 사전분포의 중심값이며 검증 점수를 보고 고르지 않았다. 이 값에서 각 슬롯은 인접한 한두 개 시각에만 가중치를 둔다. 첫 슬롯과 마지막 슬롯은 한 시각, 나머지 94개 슬롯은 두 시각을 쓴다. 예컨대 00:30–00:45 슬롯은 0시 계획에 0.75, 1시 계획에 0.25를 둔다. 결과적으로 이 커널은 인접한 두 시각 계획을 시차 없이 선형 보간하는 국소 전달함수이며 분포시차 전달함수 [15]의 가장 단순한 형태다.

날짜 효과와 슬롯 잡음은 잡음 상태 g 마다 따로 둔다. g 는 비가동($k=0$)과 가동($k \geq 1$)의 두 상태다.

$$u_d \sim \mathcal{N}(0, \sigma_{u,g}^2), \quad e_{d,t} = \rho_g e_{d,t-1} + \eta_{d,t}, \quad \eta_{d,t} \sim \mathcal{N}(0, \sigma_{\eta,g}^2). \quad (4)$$

날짜 효과 u_d 는 하루 전체를 함께 올리거나 내리는 변동이고, $e_{d,t}$ 는 슬롯 사이에 이어지는 1차 자기회귀 잡음이다. 하루의 첫 슬롯은 정상분포 $e_{d,1} \sim \mathcal{N}(0, \sigma_{\eta,g}^2/(1 - \rho_g^2))$ 에서 시작한다. 조용한 비가동일과 생산 부하가 오르내리는 가동일은 변동의 크기와 지속 시간이 다르다. 두 상태가 같은 잡음을 공유하면 비가동일의 경로가 가동일 수준으로 흔들려 일 피크가 과대평가된다. 상태별 잡음은 이 문제를 겨냥한다.

우도는 관측된 슬롯만으로 계산하고 결측 슬롯은 대체하지 않는다. 계측 결손으로 같은 날 관측 슬롯 t 와 바로 앞 관측 슬롯 $t-s$ 사이에 $s-1$ 개 슬롯이 비어 있으면, AR(1)의 s 단계 전이분포를 쓴다.

$$e_{d,t} | e_{d,t-s} \sim \mathcal{N} \left(\rho_g^s e_{d,t-s}, \sigma_{\eta,g}^2 \frac{1 - \rho_g^{2s}}{1 - \rho_g^2} \right). \quad (5)$$

그날의 첫 관측 슬롯은 정상분포에서 나온다고 둔다. 이렇게 하면 결측 구간이 잡음 추정을 왜곡하지 않고 결측이 없는 날에는 식 (4)의 우도와 같아진다. 관측오차는 가우시안이다.

2.3 베이esian 추정

모수는 시간 가중 우도를 쓰는 Gibbs–Metropolis 표집으로 추정한다. 날짜 d 의 관측은 우도에서 가중치

$$\omega_d = 2^{-(d_{\max}-d)/30} \quad (6)$$

를 받는다. $d_{\max}$ 는 학습 구간의 마지막 날이고 30일 전 자료의 가중치는 절반이다. 공장 전력 수준이 계절에 따라 움직이므로, 전 기간을 같은 무게로 쓰면 최근 수준을 따라가지 못하고 날짜 효과 분산을 과대추정한다. 가중치는 각 관측의 정밀도에 곱해진다.

평균 모수 $(\mu_{k,\cdot}, \gamma_k)$ 는 가동유형마다 결합 정규 조건부분포에서 한꺼번에 뽑는다. 현재 ρ_g 로 AR(1) 잔차를 백색화하면 우도는 $(\mu_{k,\cdot}, \gamma_k)$ 에 대한 가중 최소제곱 꼴이 된다. 그 정규방정식에 RW2 별점 $\mathbf{R}/\tau_k$ 와 γ_k 의 사전 정밀도를 더한 행렬을 Cholesky 분해해 표집한다. 평활 분산 τ_k 는 역감마 조건부분포에서 뽑는다.

날짜 효과 u_d 는 결레 정규 조건부분포에서 뽑는다. 사전분포 $\mathcal{N}(0, \sigma_{u,g}^2)$ 와 그날 백색화 잔차의 가중 우도를 결합한 것이다.

생산 이득의 로그 $\omega_{c,k}$ 와 자기상관 ρ_g 는 랜덤워크 Metropolis로 갱신한다. $\omega_{c,k}$ 의 제안은 $(\mu_{k,\cdot}, \gamma_k)$ 를 적분한 주변우도로 채택 여부를 정한다. ρ_g 는 $[0, 0.98)$ 밖의 제안을 기각한다. 혁신 분산 $\sigma_{\eta,g}^2$ 와 날짜 효과 분산 $\sigma_{u,g}^2$ 는 역감마 조건부분포에서 뽑는다.

표집은 6,000회 반복하고 앞 3,000회를 버린다. 남은 3,000개 사후표본이 예측 경로 3,000개가 된다. 수렴은 시드가 다른 사슬 사이에서 고전적 split- $\hat{R}$ [27]로 점검하고, 1.05를 넘는 모수가 있으면 수렴 실패로 표시한다. 사전분포의 구체적인 값과 한 번의 반복 절차는 부록 B에 둔다.

2.4 예측 경로와 피크 위험

예측분포는 사후표본마다 하루 경로 하나를 만들어 얻는다. 사후표본 $s = 1, \dots, S$ ($S = 3000$)의 모수로 예측일 계획에서 평균 곡선 $m_{d,t}^{(s)}$ (식 1의 앞 세 항)를 계산하고 새 날짜 효과와 AR(1) 잡음을 더한다.

$$\tilde{y}_{d,t}^{(s)} = \max\{0, m_{d,t}^{(s)} + u_d^{(s)} + e_{d,t}^{(s)}\}, \quad u_d^{(s)} \sim \mathcal{N}(0, \sigma_{u,g}^2), \quad e_{d,t}^{(s)} = \rho_g^{(s)} e_{d,t-1}^{(s)} + \eta_{d,t}^{(s)}. \quad (7)$$

잡음 상태 g 는 그날 계획의 가동유형으로 정한다. 전력은 음수가 될 수 없으므로 0에서 자른다. 난수 시드는 예측 날짜로 정해 같은 입력에서 같은 경로가 나온다.

슬롯 예측과 피크 분포는 모두 이 경로 묶음에서 계산한다. 점예측은 슬롯별 경로 중앙값이고, 분위수는 경로의 5%에서 95%까지 5% 간격 분위수(q05–q95)다. 일 피크의 분포는 경로마다 구한 최댓값 $\tilde{M}_d^{(s)} = \max_t \tilde{y}_{d,t}^{(s)}$ 의 분포이며, 피크 점예측은 그 중앙값이다. 피크 초과확률은 최댓값이 기준을 넘는 경로의 비율이다.

$$\hat{P}(M_d > C) = \frac{1}{S} \sum_{s=1}^S \mathbf{1}[\tilde{M}_d^{(s)} > C], \quad C \in \{C_{50}, C_{75}, C_{90}\}. \quad (8)$$

기준 C_{50}, C_{75}, C_{90} 은 학습 구간 가동일 가운데 결측 슬롯이 4개 이하인 날의 관측 일 피크의 50·75·90% 분위수다. 학습 구간이 바뀌면 기준도 다시 계산한다.

발행하는 위험확률은 식 (8)의 보정 전 경로 확률이다. 처음에는 예측일 직전 7일의 내부 구간에서 Platt 방식으로 한 번 더 보정했다. 그러나 이 짧은 보정 구간에는 C_{90} 초과일이 없어 절편만

추정되었고 9월 가동일의 C_{90} 위험이 모두 같은 값으로 고정되었다. 개발 구간에서도 C_{90} AUC가 보정 전 0.926, 7일 Platt 0.788로 보정 전이 높았다. 그래서 9월 결과를 보기 전에 보정 전 확률을 발행하기로 사전 등록하였다.

2.5 월 최대 갱신 경보 규칙

월 최대 갱신 경보는 그날 요금 적용 최대수요가 이미 확정된 기준선을 넘을 위험을 비용으로 환산해 경보를 낸다. 기본요금은 요금 적용 시간대(일요일·공휴일을 뺀 09-23시의 중간·최대부하 시간대)의 최대수요로 매겨진다. 이미 그 달과 래칫 기간에 기록된 최대보다 낮은 피크는 요금을 바꾸지 않는다. 따라서 위험한 날은 피크가 높은 날이 아니라 기준선을 새로 넘는 날이다.

기준선 B_d 는 00:00에 알려진 관측만으로 정한다.

$$B_d = \max \left\{ \max_{j < d, j \in \text{같은 달}} M_j^{\text{band}}, \max_{j < d, j \in \text{지난 1년의 래칫 적용월}} M_j^{\text{band}} \right\}. \quad (9)$$

M_j^{band} 는 j 일 요금 적용 시간대의 관측 최대이고 래칫 적용월은 12·1·2·7·8·9월이다. 해당 관측이 없으면 $B_d = 0$ 이다.

C-BAT 경로에서 갱신 확률과 기대 초과 비용을 계산한다. 경로 s 의 요금 적용 시간대 최대를 $\tilde{M}_d^{\text{band},(s)}$ 라 하면,

$$P_d = \frac{1}{S} \sum_s \mathbf{1}[\tilde{M}_d^{\text{band},(s)} > B_d], \quad E_d = 8,320 \text{ 원/kW} \times \frac{1}{S} \sum_s (\tilde{M}_d^{\text{band},(s)} - B_d)^+. \quad (10)$$

8,320원/kW는 적용 요금제(선택 II)의 월 기본요금 단가다. E_d 는 그날 새 최대가 생길 때 그 달 기본요금이 늘어나는 금액의 기댓값이다. 래칫으로 이후 달에 미치는 영향은 포함하지 않는다.

경보는 기대 초과 비용이 점점 비용 이상일 때 낸다. 규칙은 $E_d \geq c$ 이며, 주 가정은 담당자 1-2시간의 점점 비용인 $c = 30,000$ 원이다. 민감도 분석에는 $c = 10,000$ 원, 100,000원과 확률 기준 $P_d \geq 0.5$ 를 쓴다. 이 규칙은 확률만 보는 경보와 달리 기준선을 얼마나 넘을지까지 반영한다. 경보를 받고 조치했을 때의 절감 효과는 이 규칙이 추정하지 않는다. 위험확률과 마찬가지로 Platt 보정 없이 경로 확률을 쓴다.

3 데이터 분석

3.1 데이터와 변수

분석 자료는 한 공장의 시간별 전력·생산 기록이며, 예측 대상은 15분 단위 전력이다. 제공 파일(5. 자원 최적화 AI 데이터셋/)은 2021년 1월 1일부터 9월 14일까지 257일, 6,168행으로 이루어져 있다. 한 행에는 한 시간의 15분 전력 네 값이 들어 있어 이를 펼치면 하루 96슬롯, 모두 24,672슬롯이 된다. 예측은 매일 00:00에 당일 96슬롯을 대상으로 하며, 쓸 수 있는 정보는 전날까지의 관측 전력, 달력, 당일 시간별 생산계획이다.

전력과 생산량이 이 분석의 두 축이다(표 2). 전력은 설비가 실제로 얼마나 부하를 걸었는지를, 생산량은 그 시간에 공정이 돌았는지를 나타낸다. 피크 전력을 낮추려면 생산 일정을 바꿔야 하므로, 생산계획을 입력으로 받는 예측이 분석 목적과 바로 이어진다.

표 2: 주요 변수와 사용 여부.

변수	공정상 의미	사용
전력(kW, 15분)	공장 전체의 15분 수전 전력. 가동 설비의 부하 합	예측 목표
생산량(시간별)	그 시간에 공정이 돌았는지와 생산 규모	생산계획 $q_{d,h}$ 의 대응
요일·공휴일·월	근무 일정과 휴무	입력
기 온·습 도·풍 속·강수량	공장 밖 기상	C-BAT 미사용, 비교 모델은 전 날 관측값 사용
공장인원·평균 인건비·전기요금(계절)	전력에서 계산된 파생 열 시간대별 비용 구간	누수로 제거 예측 입력 아님

자료에는 생산실적만 있고 사전 생산계획은 없다. 본 보고서는 생산실적을 전날 확정된 생산계획의 대응으로 쓴다. 따라서 모든 결과는 당일 생산계획을 미리 안다는 가정 아래의 성능이며, 실제 계획과 실적이 다른 경우의 영향은 입력 오차 실험으로 따로 살핀다.

두 열은 전력에서 계산된 값이어서 제거하였다. 공장인원은 생산량을 그 시간 전력 네 값의 합으로 나눈 값과 일치한다(유효 6,151행, 최대 절대오차 5×10^{-9}). 평균은 전력 네 값의 반올림 평균과 6,168행 모두에서 같다. 두 열을 입력에 넣으면 목표값이 입력으로 새어 들어간다.

기상은 C-BAT 입력에서 뺐다. 공장 위치를 알 수 없어 기상 예보를 붙일 수 없고, 다음 절에서 보듯 일 피크는 기상보다 생산계획의 가동유형과 함께 움직인다.

3.2 전처리 구조

전처리는 측정값 복구와 평가 규칙을 분리한 다섯 단계로 이루어진다.

1. 원자료를 물리적 행 순서대로 적재한다. 7월 13일과 15일은 기록된 시각 열이 48행에서 행 순서와 어긋나므로 시각 열 대신 행 순서를 쓴다.
2. 15분 단위로 변환한다. 시간별 전력 네 값을 15분 슬롯으로 펼친다. 풍속 결측 3시간은 선형 보간하고, 누적 강수량은 차분하여 증분으로 바꾼다.
3. 복사일을 판정한다. 전력 96슬롯이 완전히 같은 날과 부분적으로 편집된 복사일을 찾는다.
4. 결측과 의심일을 표시한다. 전력 0은 결측으로, 7월 13일과 15일은 의심일로 표시한다.
5. 목표를 가리고 9월을 봉인한다. 복사일·의심일·결측 슬롯을 목표에서 가리고, 9월 1-14일은 목표와 입력을 모두 가린다.

복사일은 두 규칙으로 판정한다. 완전 복사는 전력 96슬롯이 소수점까지 같은 날을 한 사건으로 묶고, 원본 하나만 남긴 뒤 나머지를 복사로 표시한다(gmst/splits.py의 build_days). 묶음의 첫 날이 생산 없이 40 kW 넘는 슬롯을 48개 이상 가지면 생산이 있는 구성원을 원본으로 삼는다. 이렇게 257일은 142개 사건으로 묶이고, 그중 45개가 두 날 이상의 복사군이며, 완전 복사일은 115일이다. 같은 복사쌍의 기온·습도는 서로 다르므로 전력 곡선만 복사해 넣은 증강 자료로 판단하였다. 편집

복사는 단독 사건인 날 가운데 40 kW를 넘는 슬롯이 다른 날의 같은 슬롯과 20개 이상 같은 값을 갖는 날로, 7일이 해당한다. 두 규칙을 합친 복사일은 122일(47%)이다.

결측과 의심일은 추정하지 않고 가린다. 전력 0은 정전이나 계측 손실로 보고 결측 처리했으며, 74슬롯이 8월 28일(26슬롯), 8월 29일(46슬롯), 9월 8일(2슬롯)에 있다. 관측된 슬롯만 채점하고, 일 피크는 결측이 4슬롯 이하인 날만 평가한다. 시각 열이 어긋난 7월 13일과 15일은 목표와 생산량을 제외하되 가동일 표시는 유지한다. 공휴일(2021년 8일)은 휴무와 같다고 보지 않고 가동유형·요일과 별도 입력으로 둔다.

복사일이 가장 큰 문제다. 복사일은 모두 9월 이전에 있어 학습 구간을 부풀린다(표 3). 첫 검증 구간(f1)의 학습 구간은 달력상 186일이지만 복사일 121일을 빼면 실제 관측일은 65일이다. 학습 표본의 3분의 2가 다른 날의 사본이므로, 날짜를 무작위로 나누면 시험일의 사본이 학습에 섞인다.

표 3: 검증 구간별 학습 기간의 달력일과 복사일(일).

구간	학습 달력일	복사일	복사 제외
f1	186	121	65
f2	200	121	79
f3	214	122	92
f4	228	122	106
9월 시험	242	122	120

3.3 가동유형과 생산-전력 관계

하루 전력 곡선은 그날의 가동유형으로 대부분 갈린다. 가동유형 k 는 계획상 생산이 있는 시간 수로 정한다. 비가동($k = 0$, 0시간), 단시간($k = 1$, 1-12시간), 주간·저녁($k = 2$, 13-19시간), 종일($k = 3$, 20시간 이상)의 네 가지다. 가동유형은 생산계획에서 바로 계산되므로 예측 시점에 알 수 있다.

표 4: 가동유형별 일 피크(개발 구간 피크 평가일 51일). 고피크는 실제 피크가 학습 구간 가동일 피크의 90% 분위수(C90)를 넘는 날이다.

가동유형	일수	평균 피크(kW)	피크 범위(kW)	고�피크일
비가동(0시간)	14	27.1	26-29	0
단시간(1-12시간)	5	107.6	104-110	0
주간·저녁(13-19시간)	8	202.0	186-222	3
종일(20시간 이상)	24	199.8	173-218	10

피크 수준은 13시간 이상 가동하는 날에서만 높아진다(표 4). 비가동일의 평균 피크는 27 kW다. 단시간 가동일은 108 kW, 13시간 이상 가동일은 약 200 kW다. 고피크일 13일은 모두 13시간 이상 가동한 날이고, 모두 피크 시각에 생산이 계획되어 있었다. 13시간 이상 가동하는 날 사이에서는 평균 피크가 거의 같아 가동 시간이 더 길어져도 피크가 계속 커지지 않는다.




그림 1: 가동일의 첫 피크 시각 분포(개발 구간 37일). 짙은 색은 고평크일.

피크 시각은 08시와 11시에 몰린다(그림 1). 가동일 37일 가운데 첫 최댓값이 08시인 날이 10일, 11시인 날이 9일이다. 고평크일 13일 중 10일(08시 6일, 11시 4일)이 이 두 시각에 피크를 기록했다. 피크가 생산이 있는 특정 시각에 생기므로, 생산계획을 입력으로 받아 시각별 부하를 예측하는 모델이 필요하다. 이 관계는 사후 연관이며 표본이 작다(고피크 13일).

3.4 누수 진단과 검증 설계

복사일이 섞인 자료에서 무작위 분할은 성능을 좋게 보이게 한다. 9월 이전 241일에 대해 날짜 단위 무작위 5-fold와 LOEO(leave-one-event-out)를 비교하였다. LOEO는 같은 복사 사건에 속한 날을 함께 빼며, 사건은 126개(복사군 45개, 단독일 81개)다. 비교 모델 M2(LightGBM 기본)의 MAE는 무작위 분할에서 14.91 kW, LOEO에서 16.64 kW였다(표 5). 차이 -1.73 kW의 날짜 짝 부트스트랩 95% 구간은 0을 포함하지 않는다. 기존 BAT는 두 분할에서 거의 같았다. 학습과 시험 사이의 중복 표본이 성능을 부풀리는 전형적인 누수다[26].

표 5: 복사일 포함 자료에서의 누수 진단(MAE, kW, 241일).

모델	무작위 5-fold	LOEO	차이 [95% 구간]
M2(LightGBM 기본)	14.91	16.64	-1.73 [$-3.63, -0.04$]
기존 BAT	16.37	16.32	$+0.05$ [$-0.22, +0.42$]

이 결과에 따라 모든 모델 비교는 복사일을 목표에서 뺀 시간순 분할로 한다. 시계열에서는 무작위 교차검증보다 시간 순서를 지키는 블록 분할이 적절하다[25, 28]. 검증 구간 f1-f4는 2021년 7월 7일부터 8월 31일까지 14일씩 네 구간이다. 각 구간의 모델은 그 이전 자료만으로 학습한다. 검증 첫날 전날은 간격일로 두어 목표에서 빼고 첫 검증일의 입력으로만 쓴다. 검증 구간과 같은 복사 사건에 속한 학습일은 제거(purge)하는 규칙을 두었으나, 실제로 해당하는 날은 없었다. 네 구간에서 유효하게 채점되는 표본은 53일, 5,016슬롯이고 일 피크 평가일은 51일이다. 확률 모형은 난수 시드 0, 1, 2로 반복 적합하고 시드별 점수를 평균한다. 시드 반복은 관측일 수를 늘리지 않는다.

9월 1-14일은 최종 평가 구간으로 봉인하였다. 기본 로더가 이 구간의 목표와 입력을 모두 가린다. 이 구간은 이전 개발 단계(v2)에서 한 번 열렸으므로 완전한 미사용 구간은 아니다. 이번에는

C-BAT를 확정·동결한 뒤 한 번만 적용했고 모델 선택에는 쓰지 않았다. 그 뒤의 실험은 f1-f4에서만 사전 등록 규칙으로 평가했다.

4 결과 및 오류분석

이 장은 C-BAT를 기준선과 같은 조건에서 비교하고, 오차와 경보 실패가 어떤 조건에서 생기는지 분석한다. 모든 개발 구간 결과는 f1-f4 교차검증 fold를 합산한 값이다(53일, 5,016슬롯, 피크 평가 일 51일). 9월 구간은 마지막 절에서 한 번만 따로 보고한다.

4.1 실험 설정과 성능 비교

모든 모델은 같은 fold, 같은 결측 마스크, 같은 채점 함수로 평가했다. 비교 대상은 여섯 모델이다. B0는 지난주 같은 요일의 전력을 그대로 쓰는 단순 기준선이다. B0_kind는 과거 28일 안에서 가동유형 k 와 날짜유형이 같은 날 가운데 가장 최근 완전 관측일을 쓴다. M2는 생산계획을 입력으로 넣은 LightGBM[24]이고, LightGBM(튜닝)은 fold 안에서 슬롯 예측과 일 피크 예측의 하이퍼파라미터를 따로 고른 판이다. 기존 BAT는 라플라스 잡음과 학습형 어텐션, 공통 잡음을 쓰는 이전 모델이고, C-BAT는 가동 상태별 가우시안 잡음과 사전 고정 어텐션을 쓰는 최종 모델이다.

지표는 목적에 맞게 나눴다. 슬롯 MAE와 WAPE는 예측 중앙값으로, RMSE와 R^2 는 예측 평균으로 계산했다. 확률 예측의 품질은 CRPS[10]로 본다. 일 피크는 예측 경로의 하루 최댓값에서 구했다. 피크 MAE는 그 중앙값으로, 피크 RMSE와 R^2 는 평균으로 계산했다. 피크 시각 적중은 관측 피크 시각 ± 2 슬롯(± 30 분) 안에 예측 피크 시각이 들어간 비율이다. 확률 모델은 seed 0-2 결과를 평균했다.

표 6: 개발 구간 f1-f4 합산 성능(53일, 5,016슬롯, 피크 51일). 단위는 kW(WAPE는 %, 적중률은 비율). M2 행은 WAPE· R^2 ·피크 RMSE·피크 R^2 가 저장되어 있지 않아 비워 두었다.

모델	슬롯					일 피크			
	MAE	RMSE	R^2	WAPE	CRPS	MAE	RMSE	R^2	시각 적중
B0	26.84	52.62	0.280	29.65	–	42.22	79.37	–0.058	0.098
B0_kind	8.51	14.98	0.942	9.40	–	6.67	10.03	0.983	0.157
M2	11.64	21.46	–	–	8.96	17.02	–	–	0.157
LightGBM(튜닝)	11.05	19.78	0.898	12.20	8.65	10.07	17.94	0.946	0.118
기존 BAT	7.82	12.61	0.959	8.64	6.99	14.50	16.97	0.952	0.255
C-BAT	8.50	12.37	0.960	9.39	6.96	8.93	12.07	0.976	0.203

C-BAT는 슬롯 곡선과 확률 예측에서 가장 좋은 축에 들고, 일 피크에서는 B0_kind 다음이다(표 6, 그림 2). C-BAT의 슬롯 RMSE는 12.37 kW, CRPS는 6.96 kW로 비교 모델 중 가장 낮다. 슬롯 MAE는 기존 BAT가 7.82 kW로 가장 낮고 C-BAT(8.50 kW)와 B0_kind(8.51 kW)가 비슷하다. 생산계획을 넣은 LightGBM은 튜닝 뒤에도 슬롯 MAE 11.05 kW, CRPS 8.65 kW로 C-BAT보다 크다. B0는 슬롯 MAE 26.84 kW로 크게 뒤진다. 같은 복사 방식이라도 가동유형을 맞춘 B0_kind는 8.51 kW이므로, 기준일을 고를 때는 가동유형 일치에 관건이다.




그림 2: 주요 모델의 슬롯 RMSE, CRPS, 일 피크 MAE(개발 구간 f1-f4). LightGBM은 튜닝판이다.

C-BAT의 가장 큰 개선은 일 피크에서 나온다. 기존 BAT의 피크 MAE 14.50 kW를 8.93 kW로 줄였고, 피크 R^2 는 0.952에서 0.976으로 올랐다. 피크 MAE만 보면 B0_kind(6.67 kW)가 가장 낮지만 다음 절에서 층별로 나눠 보면 이 차이의 성격이 달라진다. 피크 시각 적중률은 기존 BAT 0.255, C-BAT 0.203으로 모든 모델이 낮다. 피크 평가일 51일 중 13일은 최댓값 근처의 부하가 여러 시각에 걸쳐 있어 하루 최댓값이 둘 이상의 슬롯에서 같게 관측된다. 이런 날은 피크 시각을 ± 30 분 안에 맞추기 어렵다.

4.2 절제와 불확실성

작은 bootstrap으로 보면 C-BAT의 피크 개선은 기존 BAT와 LightGBM(튜닝)에 대해 뚜렷하다(표 7). 차이는 C-BAT에서 비교 모델을 뺀 값이며 음수가 C-BAT에 유리하다. seed별 날짜 손실 차이를 먼저 평균한 뒤 날짜 단위로 재표집했다($B=4000$). 날짜 사이 상관을 고려해 7일 블록 재표집 구간도 함께 계산했다. 기존 BAT 대비 전체 피크 MAE는 -5.57 kW, 고평크일 피크 MAE는 -8.10 kW이고 두 구간 모두 0을 포함하지 않는다. 대신 슬롯 MAE는 $+0.68$ kW 나빠졌다(구간 $[-0.01, 1.36]$). LightGBM(튜닝) 대비로는 슬롯 MAE(-2.55 kW), CRPS(-1.69 kW), 고평크일 피크 MAE(-13.90 kW)가 모두 날짜 단위 구간에서 유리하다.

B0_kind는 전체 피크 MAE에서 C-BAT보다 낮다. 전체 피크 MAE는 6.67 kW 대 8.93 kW이고, 차이 $+2.26$ kW의 날짜 단위 구간 $[0.36, 4.12]$ 는 0을 포함하지 않는다. 반면 고평크일에서는 C-BAT가 3.17 kW 낮다. 날짜 단위 구간 $[-7.04, 0.40]$ 은 0을 조금 포함하지만 7일 블록 구간 $[-7.84, -0.11]$ 은 포함하지 않는다. B0_kind는 가동유형이 같은 최근 날을 복사하므로 평범한 날에는 잘 맞는다. 그러나 피크가 과거보다 높게 오르는 날에는 따라가지 못한다. 요금과 설비 운용은 고평크일에 좌우되므로 이 결과를 C-BAT의 약점이자 선택 근거로 함께 적는다.

절제 비교를 보면 C-BAT의 두 설계, 곧 가동 상태별 잡음과 고정 어텐션이 피크 성능을 떠받친다(표 8). 공통 잡음 비교는 학습형 어텐션 모델에서만 실행했으므로 학습형 어텐션 행과 비교한다. 잡음을 상태별에서 공통으로 바꾸면 피크 MAE가 9.16 kW에서 15.29 kW로, 고평크일 피크 MAE가 4.38 kW에서 7.80 kW로 커졌다. 어텐션을 학습형으로 바꾸면 슬롯 MAE는 0.17 kW 좋아지지만 피크 MAE가 0.23 kW 나빠지고, 최대 split- $\hat{R}$ 이 1.308로 수렴 기준을 넘는다. 종류 기준 ref는 슬롯 MAE를 7.80 kW로 낮추지만 피크 MAE와 고평크일 피크 MAE가 커진다. 기존 BAT에서 생산 전달항을 빼도 슬롯 MAE 7.73 kW, 피크 MAE 14.53 kW로 기존 BAT와 거의 같았다.

C-BAT의 표집은 모든 fold에서 수렴 기준을 만족했다. seed 3개를 체인으로 보고 상수 모수를

표 7: C-BAT와 비교 모델의 짝지은 bootstrap 차이(C-BAT – 비교 모델, kW). 괄호는 날짜 단위 95% 구간, 대괄호는 7일 블록 95% 구간. 고평크일은 13일이다.

비교 모델	지표	차이	날짜 구간	7일 블록 구간
기존 BAT	슬롯 MAE	+0.68	(−0.01, 1.36)	[0.34, 1.22]
	피크 MAE 전체	−5.57	(−8.76, −2.07)	[−12.17, −0.99]
	피크 MAE 고평크	−8.10	(−11.19, −5.80)	[−10.00, −5.73]
B0_kind	슬롯 MAE	−0.01	(−1.27, 1.08)	[−1.18, 1.21]
	피크 MAE 전체	+2.26	(0.36, 4.12)	[−0.29, 4.16]
	피크 MAE 고평크	−3.17	(−7.04, 0.40)	[−7.84, −0.11]
LightGBM(튜닝)	슬롯 MAE	−2.55	(−5.08, −0.33)	[−7.30, 0.63]
	슬롯 CRPS	−1.69	(−3.48, −0.12)	[−5.10, 0.68]
	피크 MAE 전체	−1.14	(−3.79, 1.48)	[−5.58, 2.03]
	피크 MAE 고평크	−13.90	(−19.02, −9.86)	[−18.59, −11.63]
학습형 어텐션	슬롯 MAE	+0.17	(0.07, 0.28)	[0.08, 0.23]
	피크 MAE 전체	−0.23	(−0.51, −0.00)	[−0.48, −0.04]

표 8: 절제 비교(개발 구간 f1–f4, seed 0–2 평균, kW). 공통 잡음 행은 학습형 어텐션 행과 비교한다. 기존 BAT 두 행은 split- $\hat{R}$ 기록이 없다.

모델	슬롯 MAE	RMSE	CRPS	피크 MAE	고피크 MAE	최대 $\hat{R}$
C-BAT	8.50	12.37	6.96	8.93	4.37	1.029
학습형 어텐션	8.34	12.10	6.85	9.16	4.38	1.308
공통 잡음(학습형 어텐션)	8.26	12.15	7.43	15.29	7.80	2.303
종류 기준 ref	7.80	12.80	6.86	9.06	5.02	1.038
기존 BAT	7.82	12.61	6.99	14.50	12.47	–
기존 BAT(전이 없음)	7.73	12.89	7.03	14.53	12.27	–

맨 22개 변수의 기본 $\text{split-}\hat{R}[27]$ 을 계산했다. 최댓값은 f1 내부 보정 단계의 1.029이고, 1.05를 넘은 변수는 f1-f4의 내부·외부 단계 어디에도 없었다. 이 진단은 순위 정규화 $\hat{R}[29]$ 이나 꼬리 ESS가 아니므로 수렴의 충분조건은 아니다. 구간 예측은 넓은 쪽으로 치우친다. 슬롯 90% 구간(q05-q95) 적중률은 0.990, 50% 구간 적중률은 0.781로 명목값보다 높다. 일 피크 90% 구간 적중률은 0.948로 명목값에 더 가깝다.

4.3 오차와 피크가 발생하는 조건

C-BAT의 피크 오차는 고피크일이 아니라 평범한 가동일에서 커진다(표 9, 그림 3). 개발 구간 51일을 비가동 14일, 가동 37일로 나누고, 관측 피크가 학습 fold의 C90을 넘는 13일을 고피크일로 따로 묶었다. C-BAT의 피크 MAE는 비가동일 2.50 kW, 가동일 11.36 kW, 고피크일 4.37 kW다. 고피크일 오차가 가동일 전체보다 작다. 기존 BAT는 비가동일 피크를 24.11 kW 높게 보았고, LightGBM(튜닝)은 고피크일을 20.37 kW 낮게 보았다. C-BAT는 두 실패를 모두 줄였지만 가동일에서 평균 +9.74 kW 높게 예측한다.

표 9: 피크 층별 MAE와 편향(kW). 편향은 예측 평균 - 관측이다. 고피크일 13일은 가동일 37일에 포함된다.

모델	피크 MAE				피크 편향			
	전체	비가동	가동	고피크	전체	비가동	가동	고피크
C-BAT	8.93	2.50	11.36	4.37	+7.77	+2.54	+9.74	-1.08
기존 BAT	14.50	24.11	10.86	12.47	+8.10	+24.59	+1.87	-12.24
B0_kind	6.67	0.93	8.84	7.54	+0.24	+0.36	+0.19	-4.77
LightGBM(튜닝)	10.06	2.51	12.92	18.27	+1.98	+19.47	-4.64	-20.37




그림 3: 피크 층별 일 피크 MAE(All 51일, Nonop 비가동 14일, Op 가동 37일, High 고피크 13일).

슬롯 오차는 생산 시간대의 배치에서 갈린다. 가동유형별 C-BAT 슬롯 MAE는 생산 13-19시간 날 16.7 kW, 20시간 이상 날 10.0 kW, 1-12시간 날 8.2 kW, 비가동일 1.7 kW다. 13-19시간 가동일 가운데 계획상 생산이 없는 슬롯은 MAE 20.7 kW, 편향 +13.7 kW로 가장 나쁘다. C-BAT가 생산 시작 전이나 종료 뒤의 전력을 가동 수준으로 높게 본다. 시작 시각을 보면 07시에 시작한 2일이 21.6

kW(편향 +17.8 kW), 08시에 시작한 5일이 13.5 kW로, 전날부터 이어 가동하거나 01시에 시작한 날(9.4–10.4 kW)보다 크다. 하루 중에서는 18시(11.1 kW)와 19시(10.1 kW)의 오차가 가장 크고 21–23시(약 6 kW)가 가장 작다. 08–16시에는 1.4–3.8 kW 낮게 예측한다. 일 생산량 사분위별 슬롯 MAE는 10.1–11.7 kW로 차이가 작다. 요일 가운데서는 월요일이 14.1 kW(편향 +5.2 kW)로 가장 컸다. 그림 4은 층별 대표일의 예측 곡선이다.




그림 4: 층별 대표일의 C-BAT 예측(중앙값, 50%·90% 구간)과 관측. 대표일은 층별 일 슬롯 MAE 중앙값에 가장 가까운 날이다(seed 0).

실측 고피크는 긴 가동, 특정 시각, 7월에 몰렸다. 모델과 무관한 관측 사실로, 고피크일 13일은 모두 생산 13시간 이상인 날이었다(13–19시간 3일, 20시간 이상 10일). 1–12시간 가동일 5일은 평균 피크가 108 kW로 고피크가 없었다. 고피크일 13일 중 10일은 첫 최댓값이 08시(6일)나 11시(4일)에 왔고, 13일 모두 피크 시각에 생산이 계획되어 있었다. 달로 보면 7월 22일 중 11일, 8월 29일 중 2일이 고피크였다. 다만 고피크 기준인 C90이 fold마다 달라서 생긴 차이도 섞여 있다. 일 생산량은 1사분위(평균 피크 154 kW)만 낮고 2–4사분위는 199–203 kW로 비슷했다.

가동일 과대예측의 원인은 평균 곡선이 아니라 경로 최댓값에 있다. 가동일 37일에서 C-BAT 평균 곡선의 하루 최댓값은 관측 피크보다 평균 10.9 kW 낮다. 경로 최댓값의 중앙값은 여기에 약 20.1 kW를 더해, 중앙값 기준 가동일 편향이 +9.2 kW가 된다. 추가분은 고피크일에는 알맞다. 고피크일의 평균 곡선 최댓값은 관측보다 23.5 kW 낮고, 경로 최댓값을 쓰면 편향이 –1.7 kW로

줄어든다. 그러나 고평크가 아닌 가동일 24일에는 평균 곡선 최댓값의 편향이 -4.1 kW뿐이어서, 같은 폭을 더하면 약 $+15$ kW 과대예측이 된다. 피크 오차가 가장 큰 10일은 모두 고평크가 아닌 가동일이었고 모두 17–32 kW 과대예측이었다.

모델이 두 부류의 가동일에 서로 다른 폭을 주지 못하는 이유는 생산계획에 고평크 신호가 거의 없기 때문이다. 가동일 37일에서 C-BAT 피크 오차(중앙값 – 관측, seed 평균)와 계획 특성의 상관을 계산했다. 생산 시작 시각과의 상관은 $r = -0.03$, 생산 첫 2시간의 생산량 비중과는 $r = -0.01$, 생산 시간 수와는 $r = -0.01$ 이었다. 계획만으로는 오차가 큰 날을 미리 가려낼 수 없다. 뒤의 확장 실험에서도 같은 결론이 되풀이된다.

4.4 경보의 미탐지·오경보 조건

C-BAT는 가장 드문 C90 초과에서 비교 모델보다 균형 잡힌 경보를 낸다(표 10). 경보는 “오늘 피크가 기준 C를 넘는다”는 판단이다. 확률은 fold마다 내부 보정일 7일로 적합한 Platt 보정을 거쳤고, 문턱 p^* 는 같은 fold 내부에서 F1이 가장 큰 값으로 정했다. 사건 수는 C50 31일, C75 21일, C90 13일이다. C50은 세 모델 모두 F1이 0.89 이상이다. C90에서 C-BAT의 F1은 0.584로 가장 높고 Brier 점수도 0.201로 가장 낮다. LightGBM(튜닝)은 경보를 낸 날은 모두 맞혔지만 재현율이 0.231로, 고평크 13일 중 3일만 잡았다. 매일 경보의 C90 F1(0.406)보다도 낮다.

표 10: 일 피크 초과 경보 성능(개발 구간 51일, seed 평균, fold 내부 7일 Platt 보정). 매일 경보는 모든 날에 경보를 낸 기준선이다.

기준(사건 수)	모델	정밀도	재현율	F1	AUC	Brier
C50 (31일)	C-BAT	1.000	0.882	0.937	0.997	0.020
	기준 BAT	0.967	0.935	0.951	0.976	0.020
	LightGBM(튜닝)	0.963	0.839	0.897	0.977	0.030
	매일 경보	0.608	1.000	0.756	–	–
C75 (21일)	C-BAT	0.829	0.921	0.872	0.844	0.153
	기준 BAT	0.769	0.952	0.851	0.863	0.211
	LightGBM(튜닝)	0.900	0.429	0.581	0.798	0.236
	매일 경보	0.412	1.000	0.583	–	–
C90 (13일)	C-BAT	0.520	0.667	0.584	0.788	0.201
	기준 BAT	0.417	0.769	0.541	0.800	0.233
	LightGBM(튜닝)	1.000	0.231	0.375	0.688	0.253
	매일 경보	0.255	1.000	0.406	–	–

C90 미탐지는 7월의 종일 가동일에 몰렸다. C-BAT가 놓친 날(seed 평균 4.33일)은 모두 7월이고 모두 생산 20시간 이상인 날이었다. 그중 62%가 일 생산량 상위 25%였다. 7월에 생산량이 많은 종일 가동일의 피크가 학습 구간보다 높게 올라갔고, C-BAT가 그 상승 폭을 다 따라가지 못한 것으로 보인다. 오경보(seed 평균 8일)는 앞 절의 가동일 과대예측에서 나왔다. 7월과 8월이 절반 씩이고, 생산 20시간 이상인 날이 62%, 13–19시간인 날이 38%였다. 요일로는 금요일이 38%였고 주말 오경보는 없었다. 미탐지는 여름철 부하 상승을 늦게 따라가서, 오경보는 평범한 가동일의 피크를 높게 봐서 생긴다.

경보 수치는 보정 방식에 민감하다. fold 내부 7일 Platt 보정은 적합에 쓸 날이 적다. C-BAT의 C90 AUC는 보정 전 0.926에서 보정 뒤 0.788로 떨어졌고, Brier도 0.131에서 0.201로 나빠졌다. C75도 보정 전 Brier가 0.146으로 보정 뒤(0.153)보다 낮았다. 최종 실행에서는 8월 말 7일에 C90 초과일이 없어 보정식이 절편만 추정했고, 9월 가동일의 C90 위험이 모두 0.0013으로 고정되었다. 그래서 9월 제출 파일의 위험 확률은 보정 전 경로 확률 $P(\text{경로 최댓값} > C)$ 로 발행하도록 결과를 보기 전에 규칙을 정했다. 표 10은 이전 방식으로 계산한 개발 구간 결과이므로 모델 간 상대 비교로만 읽어야 한다.

4.5 생산계획 입력 오차의 영향

C-BAT는 생산량 오차에는 거의 반응하지 않고 계획 시각 오차에 더 민감하다. 학습 입력과 채점할 실제 전력은 그대로 두고 예측일에 넣는 계획만 바꿨다. 생산량 오차는 평균이 1인 로그정규 배수(= 0.05, 0.1, 0.2, 날짜별 10회 반복)로 넣었고, 시각 오차는 계획 전체를 1시간 앞당기거나 늦춰서 넣었다. C-BAT는 seed 0 하나로 실행했다(표집 6000회, burn-in 3000회). = 0.2에서도 C-BAT의 슬롯 MAE는 8.492 kW에서 8.495 kW로 0.04% 늘었다. 계획을 1시간 이르게 넣으면 8.776 kW(+3.3%), 늦게 넣으면 8.642 kW(+1.8%)가 되었다. 기존 BAT(+0.44, +0.06 kW)와 LightGBM(튜닝)(+0.87, +0.69 kW)도 시각 오차에 더 민감했다. C-BAT의 피크 MAE는 모든 조건에서 8.6–8.9 kW였다. 전력이 생산량의 크기보다 가동 여부와 가동 시간대를 따른다는 앞 절의 관측과 맞는다. 현장에서는 생산량보다 가동 시작·종료 시각의 입력 정확도가 더 중요하다. 계획 취소나 설비 고장처럼 가동 여부 자체가 바뀌는 경우는 이 실험에 없다.

4.6 9월 시험

9월 1–14일 시험에서는 M2가 C-BAT보다 나았다(표 11). 이 구간은 v2 개발 중에 한 번 열린 적이 있고, 동결한 C-BAT로 한 번 더 열었다. 결과를 본 뒤 모델을 고치거나 다시 돌리지 않았다. 다른 모델은 다시 적합하지 않고 저장된 예측을 같은 채점 함수로 계산했다. 관측 슬롯은 1,342개로 네 모델이 같다. 한 번 열린 구간이므로 오염되지 않은 홀드아웃이 아니며, 모델 선택 근거는 f1–f4 결과로 둔다.

표 11: 9월 시험(2021-09-01–14, 14일, 1,342슬롯). Brier는 C50·C75·C90 보정 전 위험의 평균이다. 기존 BAT와 M2, B0는 v2 때 저장된 예측이다.

모델	슬롯 MAE	RMSE	R^2	CRPS	90% 적중	피크 MAE	시각 적중	Brier
B0	7.88	11.18	0.962	–	–	7.00	0.143	0.119
M2	6.60	9.75	0.971	5.03	0.872	5.53	0.286	0.121
기존 BAT	6.82	9.53	0.972	5.51	0.948	7.98	0.286	0.112
C-BAT	7.18	9.79	0.971	5.71	0.984	8.93	0.286	0.161

C-BAT와 M2의 슬롯 MAE 차이는 표본이 작아 유의하지 않다. C-BAT – M2는 +0.58 kW이고 날짜 단위 bootstrap 95% 구간은 $[-0.24, 1.43]$ 이다. 9월에는 C90 초과일이 하루도 없어서 C-BAT의 강점인 고평크일 성능을 시험할 기회가 없었다. 대신 약점인 가동일 과대예측은 그대로 나타났다. 9월 가동일 12일의 피크 편향(중앙값 기준)은 +10.2 kW로, 개발 구간의 +9.2 kW(중앙값

기준)·+9.7 kW(평균 기준)와 같은 수준이다. 90% 구간 적중률도 0.984로, 개발 구간처럼 구간이 넓다.

위험 확률은 보정 전 경로 확률로 발행했다. 규칙을 정한 뒤 한 번만 계산한 9월 Brier는 C50 0.131, C75 0.304, C90 0.047이다. 이전 7월 Platt 방식은 C75(0.111)와 C90(0.000)에서 더 낮았다. 그러나 C90의 0.000은 초과일이 없는 구간에서 위험을 상수로 꺼 버려 나온 값이고 판별력과는 관계가 없다. 보정 전 위험은 C50에서 낮고, C75·C90에서는 평범한 가동일 과대예측 때문에 위험을 높게 낸다(C90 최대 0.30).

4.7 확장 실험과 최종 모델 선택

C-BAT를 고친 뒤 사전 등록한 확장 실험 11가지를 f1~f4에서만 평가했고 채택된 것은 없다(표 12). 각 실험은 결과를 보기 전에 채택 조건을 문서로 고정했다. 조건은 실험마다 조금 다르지만 공통으로 C-BAT의 전체 피크 MAE(8.93 kW)와 고평크일 피크 MAE(4.37 kW)를 지키면서 곡선이나 가동일 편향을 개선하도록 요구했다. 9월 구간은 쓰지 않았다.

표 12: 사전 등록 확장 실험(개발 구간 f1~f4, seed 0~2 평균, kW). 양상블은 C-BAT seed 0과 비교했고 fold 하나씩 뺀 가중치로 평가했다. 양상블의 피크는 C-BAT와 같다.

분류	변형	슬롯 MAE	피크 MAE	고피크 MAE	불합격 사유
기준	C-BAT	8.50	8.93	4.37	–
잡음	가동유형 4상태	8.76	9.18	6.50	가동일 편향, 고평크
	슬롯 4상태	8.96	10.47	6.80	가동일 편향, 적중률, 고평크
	Student- <i>t</i> 혁신	8.70	9.90	4.53	가동일 편향, 적중률
	가동유형 + <i>t</i>	8.99	10.49	7.30	네 조건 모두
기준일	종류 기준(kind)	7.80	9.06	5.02	전체 피크
	계획 기준(plan)	7.63	9.80	5.16	가동일 편향, 고평크
	어텐션, 전달항 없음	7.92	11.69	4.85	전체 피크
	어텐션 + 전달항	7.76	11.93	4.57	전체 피크
피크 계층	v1 기준일 피크 회귀	7.76	11.85	21.70	전체 피크, 고평크
	v2 C-BAT 피크 사전	7.76	12.27	20.73	전체 피크, 고평크
양상블	M2 + C-BAT	8.82	–	–	슬롯 MAE(C-BAT 8.49)

확장 실험은 곡선이나 한 층만 개선했고, C-BAT의 피크 균형을 넘은 것은 없었다. 기준일을 바꾼 네 실험은 슬롯 MAE를 7.63~7.92 kW로 낮췄지만 피크 MAE가 9.06~11.93 kW로 커졌다. 어텐션 기준일 두 모형에서는 가동일 편향이 +14.3, +14.7 kW로 늘었다. 잡음 변형 4종은 구간을 넓혀 경로 최댓값을 더 끌어올렸고 가동일 편향이 +9.38~+12.45 kW로 오히려 커졌다. 전용 피크 계층은 비가동일 피크 MAE(v1 1.07 kW)와 C90 정보 F1(v1 0.686)을 개선했다. 그러나 선형 회귀가 가동일 피크를 평균 쪽으로 수축시켜 고평크일을 20 kW 넘게 낮게 보았다. M2와의 점예측 양상블은 fold마다 고른 가중치가 0.05~0.30으로 흔들렸고, fold 하나씩 뺀 슬롯 MAE가 8.82 kW로 C-BAT(8.49 kW)보다 나빴다. 여러 방향에서 같은 결과가 나온 것은 앞에서 본 한계 때문이다. 생산계획에는 평범한 가동일과 고평크일을 가르는 정보가 거의 없어서, 곡선을 바꾸든 피크를 따로

모형화하던 한쪽을 맞추면 다른 쪽이 나빠진다.

최종 모델로 C-BAT를 고른 근거는 개발 구간의 피크 성능이다. C-BAT는 고평크일 피크 MAE 4.37 kW로 모든 비교 모델과 확장 실험 중 가장 낮고 기존 BAT와 LightGBM(튜닝) 대비 개선의 bootstrap 구간이 0을 포함하지 않는다. C90 경보의 F1과 Brier도 비교 모델 중 가장 좋다. 곡선과 구간 품질에서는 슬롯 RMSE와 CRPS가 가장 낮고 피크 90% 구간 적중률이 0.948로 명목값에 가깝다. 여기에 경로 표본에서 초과 확률 $P(\text{경로 최댓값} > C)$ 를 바로 얻을 수 있어 5장의 피크 위험 운용에 쓸 수 있다. 다만 전체 피크 MAE는 B0_kind보다 2.26 kW 크고 평범한 가동일을 약 9–10 kW 높게 예측한다. 9월 시험에서는 슬롯 MAE와 피크 MAE 모두 M2보다 나빴고, 고평크일이 없어 강점을 확인하지 못했다. 이 결과를 함께 밝히고, 5장에서는 C-BAT의 점예측보다 고평크 위험 신호를 중심으로 쓴다.

5 현장 활용방안

C-BAT는 일정 이동의 절감액을 계산하는 데 쓰지 않고 월 최대를 새로 쓸 위험이 큰 날을 전날 밤에 알리는 데 쓴다. 기본요금은 매일의 피크가 아니라 월 최대를 갱신하는 소수의 날이 정하기 때문이다. 이 장은 요금을 정하는 날과 경보 규칙을 정의하고, 규칙을 과거 날짜에 적용해 실제 관측으로 채점한 결과와 경보일의 조치를 제시한다. 마지막으로 모형의 반사실 일정 이동을 저감 근거로 쓰지 않는 이유와 현장 검증 방법을 적는다.

5.1 요금을 정하는 날과 경보 규칙

기본요금은 매달 요금시간대의 최대수요와 래킷 하한 가운데 큰 값으로 정해진다. 요금시간대는 일요일·공휴일을 뺀 09–23시의 중간·최대부하 시간대다. 래킷 하한은 지난 1년 동안 래킷 적용월 (12·1·2·7·8·9월)의 최대수요에서 온다. 따라서 청구 수요를 움직이는 날은 그 달의 최대를 새로 쓰는 날뿐이다.

개발 구간(2021년 7월 7일–8월 31일) 가운데 요금시간대 관측이 있는 44일에서 월 최대를 갱신한 날은 7월 19일 하루였다. 그날 요금시간대 최대는 222 kW로, 전날까지의 기준선 206 kW를 16 kW 넘었다. 기본요금 8,320원/kW·월을 적용하면 그 달 기준 133,120원이다. 7월은 래킷 적용월이므로 이 초과분은 이후 최대 11개월의 하한에도 영향을 줄 수 있다. 연 단위로는 $133,120\text{원} \times 12 \approx 160\text{만 원}$ 이 상한이며, 이후 달의 실제 피크가 높으면 줄어든다. 실제로 8월의 요금시간대 최대는 207 kW였지만 청구 수요는 7월이 만든 래킷 222 kW였다.

경보 규칙은 백테스트 결과를 보기 전에 정해 기록하였다. 예측일 d 의 00:00에 다음 절차를 실행한다.

1. 기준선 B_d 를 구한다. B_d 는 이번 달 1일부터 전날까지의 요금시간대 관측 최대와, 이번 달 이전 래킷 적용월의 요금시간대 관측 최대 가운데 큰 값이다. d 일 이전 관측만 쓴다.
2. C-BAT 사후 경로 $s = 1, \dots, S$ 마다 요금시간대 슬롯의 최댓값 $M_d^{(s)}$ 를 구한다.
3. 갱신 확률 P_d 와 기대 초과 기본요금 E_d 를 계산한다.

$$P_d = \frac{1}{S} \sum_{s=1}^S \mathbf{1}[M_d^{(s)} > B_d], \quad E_d = 8,320 \times \frac{1}{S} \sum_{s=1}^S \max(0, M_d^{(s)} - B_d). \quad (11)$$

시드 3개(0·1·2)의 평균을 쓴다.

4. E_d 가 점검 비용 3만 원(담당자 1~2시간 가정) 이상이면 경보한다. 1만 원, 10만 원, $P_d \geq 0.5$ 는 민감도로 본다.

위험은 Platt 보정을 거치지 않은 경로 비율을 그대로 쓴다. 7일 내부 보정은 보정 구간에 C90 초과일이 없으면 절편만 추정되어 모든 날의 위험을 같은 값으로 만든다. 개발 구간에서도 C90 판별력은 보정 전 AUC 0.926, 7일 Platt 보정 뒤 0.788로 보정 전이 높았다.

5.2 백테스트와 경보일 조치

주 규칙은 유일한 갱신일인 7월 19일을 잡았고, 44일 동안 10번 경보했다(표 13). 기준일을 그대로 쓰는 B0_kind는 이날을 놓쳤다. 표의 금액은 갱신일의 피크를 기준선 아래로 완벽하게 막았다고 가정한 그 달 기준 상한이다.

표 13: 월 최대 갱신 경보 백테스트(2021년 7월 7일~8월 31일 중 요금시간대가 있는 44일, 갱신일 1일).

규칙	갱신일 잡음	경보 수	오경보	금액 상한(원)
$E_d \geq 1$ 만 원	1/1	23	22	133,120
$E_d \geq 3$ 만 원(주 규칙)	1/1	10	9	133,120
$E_d \geq 10$ 만 원	1/1	3	2	133,120
$P_d \geq 0.5$	1/1	3	2	133,120
C-BAT 점예측 $> B_d$	1/1	3	2	133,120
B0_kind 기준일 $> B_d$	0/1	0	0	0
매일 경보	1/1	44	43	133,120

C-BAT는 7월 19일에 갱신 확률 0.58, 기대 초과 비용 약 12.3만 원(122,919원)을 냈다. 경로 최댓값의 중앙값은 211 kW였다. B0_kind의 기준일 곡선은 이날 요금시간대 최대를 195 kW로 두어 기준선에 못 미쳤다. 점검 비용을 10만 원으로 올리면 경보는 3번으로 줄고 갱신일은 여전히 잡힌다.

주 규칙의 오경보 9건은 7월 초(7월 7~16일)에 몰렸다. 이 기간에는 기준선 206 kW가 평소 가동일 피크와 가까웠고, 여기에 C-BAT가 평범한 가동일의 피크를 높게 예측하는 경향이 겹쳤다. 갱신일이 1일뿐이므로 이 결과는 성능 추정이 아니라 사례다.

경보일에는 관측 근거가 있는 조치만 권한다. 최종 적용은 설비·작업 순서·납기를 아는 담당자가 정한다.

- 기동 부하 분산. 초반 두 시간에 생산을 몰지 않고 주요 설비를 차례로 켜다. 유사일 비교에서 초반 두 시간 생산 비중이 10%p 높은 날은 요금시간대 피크가 9.3 kW 높았다.
- 08시·11시 동시 기동 회피. 개발 구간 고피크일 13일 가운데 10일이 08시나 11시에 피크를 기록했다. 11시는 여름철 최대부하 시간대로 기본요금 산정에 들어간다.
- 기준선 근접 시 비필수 부하 지연. 당일 요금시간대 부하가 B_d 에 가까워지면 비필수 부하를 뒤로 미룬다.

조치의 방향은 모형과 무관한 유사일 비교에서 왔다. 2021년 9월 이전 가동일 가운데 가동유형과 날짜유형이 같고 일 생산량 차이가 10% 이내인 날로 쌍을 만들고 시작 시각이나 초반 생산 비중만 다른 쌍의 실측 피크를 비교했다. 시작이 늦은 날의 쌍 206개에서는 늦게 시작한 날의 요금시간대 피크가 더 높았다. 피크 차이의 합을 시작 지연의 합으로 나누면 1시간당 7.4 kW였다(95% 구간 [3.4, 12.0]). 그러나 쌍별 피크 차이의 중앙값은 2.0 kW로, 큰 차이는 일부 쌍에 몰려 있다. 초반 두 시간 비중이 다른 쌍은 25개뿐이었고 10%p당 9.3 kW(95% 구간 [0.6, 20.2])였다. 한 날이 여러 쌍에 들어가므로 구간은 실제보다 좁을 수 있고, 시작 시각은 수주량이나 설비 상태와 함께 움직일 수 있다. 따라서 이 값은 관측된 연관이며 조치의 효과 크기로 쓰지 않는다.

5.3 모형 반사실을 쓰지 않는 이유와 현장 검증

C-BAT로 생산계획만 바꾼 반사실 곡선을 계산하면 일정 이동의 절감액을 낼 수 있지만, 그 금액은 관측으로 뒷받침되지 않았다. 앞의 유사일 231쌍에서 두 날의 실측 차이와, 두 날의 계획을 서로 바꿔 넣은 모형 차이를 비교했다. 전력량요금 차이의 상관은 -0.01 이었고 평균 방향도 반대였다. 관측에서는 시작이 늦은 날이 하루 7,359원 비쌌지만 모형은 464원 싸다고 예측했다. 요금시간대 피크에서는 모형의 반응이 관측 차이의 약 $1/10$ 이었다(관측 $+11.0$ kW, 모형 $+0.2$ kW). 날짜 단위 cluster bootstrap 95% 구간은 0을 포함했다. 관측 쌍은 계획 외의 조건도 다를 수 있어 인과 기준값은 아니다. 그래서 모형이 틀렸다고 결론짓지는 않으며 모형 절감액을 관측으로 뒷받침할 수 없다는 데서 멈춘다.

실제 기본요금 규칙을 적용하면 기존의 일정 이동 권고는 기본요금을 바꾸지 못한다. 7월 청구 수요는 7월 19일 하루가 정했는데, 권고일에 이날은 없었다. 8월은 7월이 만든 래치 222 kW가 청구 수요를 정해, 8월 피크를 얼마나 낮추든 기본요금이 같다. 권고의 기본요금 변화는 7·8월 모두 0원이었고, 모형의 피크 감소를 10배로 키워도 0원이었다. 남은 전력량요금 절감은 위 검증에서 지지되지 않았다. 이 때문에 절감 주장은 관측된 요금 구조, 즉 갱신일 하루가 만든 금액 상한까지로 제한한다.

조치의 효과는 현장 운영으로 검증한다. 경보가 난 날을 번갈아 조치일과 비조치일로 나누고 두 집단의 요금시간대 피크를 비교한다. 갱신일이 드물기 때문에 비교 지표는 갱신 여부가 아니라 경보일의 요금시간대 피크로 둔다. 이 비교는 모형과 유사일 분석이 줄 수 없는 인과 근거를 준다.

도입은 다음 순서로 진행한다.

1. 매일 00:00에 다음 날 생산계획으로 C-BAT를 실행해 B_d , P_d , E_d , 피크 분포와 가장 가능성이 높은 피크 시각을 담은 일일 보고를 만든다.
2. 담당자가 경보일 보고를 확인하고 설비·작업 순서·납기를 고려해 위 조치 가운데 적용할 것을 정한다. 적용 여부와 내용을 기록한다.
3. 매월 말에 경보 수, 오경보, 갱신일 포착 여부, 조치일과 비조치일의 요금시간대 피크를 검토하고 점검 비용 기준을 조정한다.

6 차별성과 결론

6.1 창의성 및 차별성

C-BAT의 차별점은 새 알고리즘이 아니라, 시간별 생산계획을 입력으로 받는 해석 가능한 구조에서 하루 경로의 분포를 만들고 그 분포를 요금에 정해지는 방식에 맞춰 쓴 조합에 있다. 표 14는 이 과제에서 쓸 수 있는 기존 접근과 C-BAT를 다섯 가지 기능으로 비교한다. 표시는 각 접근의 일반적인 형태를 기준으로 하며 기존 BAT의 월 최대 경보는 경로를 만들 수 있지만 이 보고서에서 적용하지 않았다는 뜻이다.

표 14: 기존 접근과 C-BAT의 기능 비교(○ 제공, △ 부분 제공 또는 미적용, × 없음).

접근	시간별 계획	예측분포·경로	피크 위험확률	월 최대 경보	해석 가능성
유사일·B0 기준일	×	×	×	×	○
GAM·평활 가법모형 [11]	△	△	△	×	○
LightGBM [24]	○	△	△	×	△
기존 BAT	○	○	○	△	○
C-BAT	○	○	○	○	○

각 요소는 측정된 효과와 연결된다. 가동 상태별 잡음은 비가동일과 가동일에 다른 변동을 주는 요소로, 기존 BAT 대비 고평크일 피크 MAE 개선 8.1 kW 가운데 약 3.4 kW를 설명한다. 절제 실험에서 잡음을 공통으로 되돌리면 비가동일 피크 MAE가 2.44 kW에서 30.04 kW로 나빠졌다. 그 결과 고평크일 피크 MAE는 4.37 kW로, 기존 BAT 12.47 kW와 LightGBM(튜닝) 18.27 kW보다 작았다. 하루 경로를 직접 만들기 때문에 요금시간대 최댓값의 분포를 계산할 수 있고 이 분포로 만든 경보가 7-8월의 유일한 월 최대 갱신일(7월 19일)을 잡았다. 시점별 분위수만 내는 모형이나 기준일을 그대로 쓰는 B0_kind로는 같은 계산을 할 수 없거나 이날을 놓쳤다.

평가 절차도 차별점이다. 복사일 122일을 찾아 누수 규모를 정량화한 뒤 시간순 검증을 설계했고 [26], 기준일 규칙·잡음 변형·경보 규칙은 결과를 보기 전에 채택 기준을 기록한 뒤 평가했다. 모형의 반사실 일정 이동 절감액은 관측 유사일 검증에서 지지되지 않아 주장하지 않았다. 에너지 인지 스케줄링 연구가 설비 전력을 알려진 값으로 두는 것 [21, 22]과 달리, 이 보고서는 모형 출력을 관측으로 확인한 범위에서만 현장 제안에 썼다.

6.2 한계와 결론

범위가 좁다. 자료는 한 공장의 2021년 1-9월이고, 모형 비교는 7-8월 개발 구간 56일과 그 안의 고평크일 13일에서 이뤄졌다. 개발 구간은 여러 모델 비교에 반복해서 쓰였으므로 비교는 탐색적이다. 다른 계절과 다른 공장으로 일반화되는지는 확인하지 않았다.

방법에도 한계가 남아 있다. C-BAT는 고평크가 아닌 평범한 가동일의 피크를 높게 예측하는 경향이 있고 이것이 7월 초 경보의 오경보 9건으로 이어졌다. 전체 일 피크 MAE는 단순 기준선 B0_kind가 더 작았고, 슬롯 90% 구간은 필요보다 넓었다.

데이터 제약도 있다. 사전 생산계획이 없어 생산실적을 계획의 대용으로 썼다. 설비별 전력이나 설비 동시 가동 정보가 없어 피크를 만드는 설비를 특정할 수 없다. 전력 곡선이 다른 날과 똑같은

복사일 122일을 제외해 학습 자료가 줄었다.

일반화 근거는 약하다. 동결한 C-BAT로 한 번 연 9월 1–14일 구간에서는 LightGBM 기본 모형 (M2)이 슬롯 MAE 6.60 kW, 일 피크 MAE 5.53 kW로 C-BAT(7.18 kW, 8.93 kW)보다 좋았다. 9월에는 고피크일이 하루도 없어 C-BAT의 주된 장점을 시험할 수 없었고 9월 구간은 이전 개발 때 한 번 열린 적이 있어 오염되지 않은 홀드아웃이 아니다. 월 최대 갱신 사례도 1건뿐이다.

향후 과제는 세 가지다. 설비별 전력과 가동 기록을 받아 가동 부하와 동시 가동을 모형에 넣는다. 경보일을 조치일과 비조치일로 나누는 현장 A/B 운영으로 조치의 실제 효과를 측정한다. 여러 계절과 여러 번의 월 최대 갱신을 포함하는 긴 기간으로 경보 규칙을 다시 평가한다.

이 보고서는 시간별 생산계획으로 15분 전력과 일 피크의 확률분포를 예측하는 C-BAT를 제시했다. 가동 상태별 잡음과 고정 커널을 쓴 C-BAT는 개발 구간 고피크일의 피크 MAE를 4.37 kW로 낮췄다. 같은 경로로 계산한 월 최대 갱신 경보는 7–8월의 유일한 갱신일을 잡았으며 그 달 기준 금액 상한은 133,120원이다. 다만 9월에는 우위가 나타나지 않았고 경보 근거는 사례 1건이므로, 현장 도입은 A/B 운영으로 효과를 확인하면서 단계적으로 진행해야 한다.

참고문헌

- [1] Jessica Walther and Matthias Weigold. A systematic review on predicting and forecasting the electrical energy consumption in the manufacturing industry. *Energies*, 14(4):968, 2021. doi: 10.3390/en14040968.
- [2] Changzhi Lai, Yu Wang, Kai Fan, Qilin Cai, Qing Ye, Haoqiang Pang, and Xi Wu. An improved forecasting model of short-term electric load of papermaking enterprises for production line optimization. *Energy*, 245:123225, 2022. doi: 10.1016/j.energy.2022.123225.
- [3] André Trenz, Christoph Hoffmann, Christopher Lange, and Richard Öchsner. Increasing energy efficiency and flexibility by forecasting production energy demand based on machine learning. In *Manufacturing Driving Circular Economy (GCSM 2022)*, Lecture Notes in Mechanical Engineering, pages 449–456. Springer, 2023. doi: 10.1007/978-3-031-28839-5_50.
- [4] Nahyeon Kim, Aravindh Balaraman, Keun-Woo Lee, and Taewoon Kim. Multi-step peak power forecasting with constrained conditional transformer for a large-scale manufacturing plant. *IEEE Access*, 11:136692–136705, 2023. doi: 10.1109/ACCESS.2023.3339120.
- [5] Keunwoo Lee, Jungmin Ahn, and Juyong Lee. Day-ahead industrial peak demand forecasting: A shipyard benchmark of deep learning forecasters and stacking ensembles. *International Journal of Electrical Power & Energy Systems*, 178:111933, 2026. doi: 10.1016/j.ijepes.2026.111933.
- [6] Kevin Berk, Alexander Hoffmann, and Alfred Müller. Probabilistic forecasting of industrial electricity load with regime switching behavior. *International Journal of Forecasting*, 34(2):147–162, 2018. doi: 10.1016/j.ijforecast.2017.09.006.

- [7] Tao Hong and Shu Fan. Probabilistic electric load forecasting: A tutorial review. *International Journal of Forecasting*, 32(3):914–938, 2016. doi: 10.1016/j.ijforecast.2015.11.011.
- [8] Tao Hong, Pierre Pinson, Shu Fan, Hamidreza Zareipour, Alberto Troccoli, and Rob J. Hyndman. Probabilistic energy forecasting: Global energy forecasting competition 2014 and beyond. *International Journal of Forecasting*, 32(3):896–913, 2016. doi: 10.1016/j.ijforecast.2016.02.001.
- [9] Roger Koenker and Gilbert Bassett. Regression quantiles. *Econometrica*, 46(1):33–50, 1978. doi: 10.2307/1913643.
- [10] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. doi: 10.1198/016214506000001437.
- [11] Rob J. Hyndman and Shu Fan. Density forecasting for long-term peak electricity demand. *IEEE Transactions on Power Systems*, 25(2):1142–1153, 2010. doi: 10.1109/TPWRS.2009.2036017.
- [12] Yvenn Amara-Ouali, Matteo Fasiolo, Yannig Goude, and Hui Yan. Daily peak electrical load forecasting with a multi-resolution approach. *International Journal of Forecasting*, 39(3):1272–1286, 2023. doi: 10.1016/j.ijforecast.2022.06.001.
- [13] Ciaran Gilbert, Jethro Browell, and Bruce Stephen. Probabilistic load forecasting for the low voltage network: Forecast fusion and daily peaks. *Sustainable Energy, Grids and Networks*, 34:100998, 2023. doi: 10.1016/j.segan.2023.100998.
- [14] Håvard Rue and Leonhard Held. *Gaussian Markov Random Fields: Theory and Applications*. Chapman and Hall/CRC, 2005. doi: 10.1201/9780203492024.
- [15] Leah J. Welty, Roger D. Peng, Scott L. Zeger, and Francesca Dominici. Bayesian distributed lag models: Estimating effects of particulate matter air pollution on daily mortality. *Biometrics*, 65(1):282–291, 2009. doi: 10.1111/j.1541-0420.2007.01039.x.
- [16] R. A. Rigby and D. M. Stasinopoulos. Generalized additive models for location, scale and shape. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 54(3):507–554, 2005. doi: 10.1111/j.1467-9876.2005.00510.x.
- [17] Patrick L. McDermott and Christopher K. Wikle. A model-based approach for analog spatio-temporal dynamic forecasting. *Environmetrics*, 27(2):70–82, 2016. doi: 10.1002/env.2374.
- [18] Bryan Lim, Serkan Ö. Arık, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748–1764, 2021. doi: 10.1016/j.ijforecast.2021.03.012.

- [19] André F. T. Martins and Ramón F. Astudillo. From softmax to sparsemax: A sparse model of attention and multi-label classification. In *Proceedings of the 33rd International Conference on Machine Learning*, volume 48 of *Proceedings of Machine Learning Research*, pages 1614–1623, 2016. URL <https://proceedings.mlr.press/v48/martins16.html>.
- [20] Christian Gahm, Florian Denz, Martin Dirr, and Axel Tuma. Energy-efficient scheduling in manufacturing companies: A review and research framework. *European Journal of Operational Research*, 248(3):744–757, 2016. doi: 10.1016/j.ejor.2015.07.017.
- [21] Kan Fang, Nelson Uhan, Fu Zhao, and John W. Sutherland. A new approach to scheduling in manufacturing for power consumption and carbon footprint reduction. *Journal of Manufacturing Systems*, 30(4):234–240, 2011. doi: 10.1016/j.jmsy.2011.08.004.
- [22] Fadi Shrouf, Joaquin Ordieres-Meré, Alvaro García-Sánchez, and Miguel Ortega-Mier. Optimizing the production scheduling of a single machine to minimize total energy consumption costs. *Journal of Cleaner Production*, 67:197–207, 2014. doi: 10.1016/j.jclepro.2013.12.024.
- [23] Maryam H. Shoreh, Pierluigi Siano, Miadreza Shafie-khah, Vincenzo Loia, and João P. S. Catalão. A survey of industrial applications of demand response. *Electric Power Systems Research*, 141:31–49, 2016. doi: 10.1016/j.epsr.2016.07.008.
- [24] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154, 2017. URL https://papers.nips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html.
- [25] David R. Roberts, Volker Bahn, Simone Ciuti, Mark S. Boyce, Jane Elith, Gurutzeta Guillera-Arroita, Severin Hauenstein, José J. Lahoz-Monfort, Boris Schröder, Wilfried Thuiller, David I. Warton, Brendan A. Wintle, Florian Hartig, and Carsten F. Dormann. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8):913–929, 2017. doi: 10.1111/ecog.02881.
- [26] Sayash Kapoor and Arvind Narayanan. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804, 2023. doi: 10.1016/j.patter.2023.100804.
- [27] Andrew Gelman and Donald B. Rubin. Inference from iterative simulation using multiple sequences. *Statistical Science*, 7(4):457–472, 1992. doi: 10.1214/ss/1177011136.
- [28] Christoph Bergmeir, Rob J. Hyndman, and Bonsoo Koo. A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120:70–83, 2018. doi: 10.1016/j.csda.2017.11.003.

- [29] Aki Vehtari, Andrew Gelman, Daniel Simpson, Bob Carpenter, and Paul-Christian Bürkner. Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC (with discussion). *Bayesian Analysis*, 16(2):667–718, 2021. doi: 10.1214/20-BA1221.

A 코드 구성 및 재현성

제출 예측은 저장소 루트에서 명령 두 줄로 원자료 전처리부터 학습, 추론, 결과 파일 생성까지 자동으로 재현된다. 보고서의 모든 표와 그림도 모듈 하나당 명령 하나로 다시 만들 수 있다. 이 부록은 실행 환경, 코드 구성, 결과와 명령의 대응, 자료 분할과 누수 점검, 반복 설정과 사전 등록 기록을 차례로 적는다.

A.1 한 명령 실행과 환경 고정

제출 파일은 다음 두 명령으로 만든다.

```
uv sync
uv run python main.py
```

`main.py`는 2021년 9월 1일 이전 자료로 최종 C-BAT를 적합하고(6,000회 반복, 앞 3,000회 버림, 시드 0) 9월 1–14일을 예측해 `results_v3/submission/test_predictions.csv`에 쓴다. 14일 $\times$ 96슬롯의 1,344행이며 평균·중앙값, 5–95% 분위수, 일 피크 분포의 중앙값과 평균, 최빈 피크 시각, 보정 전 경로 초과확률을 담는다. CPU에서 약 1분 걸리고 GPU, 외부 자료, 네트워크 접속은 필요 없다.

환경은 Python 3.13 이상과 `uv`를 쓴다. 직접 의존성은 `numpy`, `polars`, `lightgbm`, `matplotlib` 네 개다. 모든 패키지 버전은 `uv.lock`에 고정되어 있고, `uv`를 쓰지 않는 환경을 위해 같은 버전을 `requirements.txt`로 내보냈다. 작은 행렬 연산에서는 다중 스레드 BLAS가 오히려 느려서 `main.py`와 실험 러너는 `OMP_NUM_THREADS` 등 스레드 수를 1로 고정하고 작업 단위로 병렬 실행한다.

A.2 코드 구성

코드는 `gmst/` 패키지 하나에 모여 있고 모듈은 역할별로 나뉜다(표 15).

A.3 결과와 명령의 대응

보고서의 표와 그림은 표 16의 명령으로 재현한다. 모든 명령은 `uv run python -m`으로 실행하며 스레드 수 1을 권장한다. C-BAT를 적합하는 명령에는 `--n-iter 6000 --burn 3000`을 붙이고, 비교 실험은 `--source results_v3/robustness`로 기준 모델 예측을 읽는다. 앞 단계의 출력을 뒤 단계가 읽으므로 표의 순서대로 실행한다.

피크 조건 분석은 C-BAT의 개발 구간 예측을 읽도록 다음 인자를 준다.

표 15: gmst/ 모듈 구성.

구분	모듈	역할
자료	contracts, preprocess, splits, features, lgbm_features	측정값 정리, 복사일·결측·봉인 규칙, 시간순 fold, 특징
기준 모델	baselines, backbone, benchmark_models	B0, B0_kind, LightGBM(기본·튜닝), RW2 기본곡선
모델	conditional_bat, conditional_ar, bat	C-BAT, 결측 간격 AR(1) 우도, 기존 BAT·고정 커널
평가	evaluate, analysis, conditional_diagnostics, rescore, robustness, leakage_v3	지표, 부트스트랩, 수렴 진단, 기준 모델 예측, 누수 진단
피크·요금	peak_conditions, plan_sensitivity, analog_days, billing_alarm, scenario	피크 조건, 계획 민감도, 유사일 비교, 경보 백테스트, 2021 요금표
러너	run_conditional, run_v3	C-BAT 실험·비교·9월 예측, 기존 BAT 파이프라인
보고	report_tables, report_figures, report_v3, paper_figures	저장된 예측으로 표·그림 생성(재적합 없음)

```
uv run python -m gmst.peak_conditions --source results_v3/attention_ablation
--model BAT_conditional_gaussian_fixed_attention --out results_v3/peak_conditions_v2
```

각 실행은 설정, 입력 자료와 코드의 해시, 9월 구간 개봉 여부를 run_status.json에 남긴다. 따라서 어떤 코드와 자료로 어떤 결과가 나왔는지 사후에 확인할 수 있다.

A.4 자료 분할과 9월 봉인

자료는 날 단위로 나누고 시간 순서를 지킨다. 개발 구간은 2021년 7월 7일–8월 31일을 14일씩 네 fold(f1–f4)로 나눈 rolling origin 검증이다. 각 fold는 그 이전 날로만 학습한다. 시험 구간인 9월 1–14일의 전력값은 기본 로더에서 결측으로 봉인되어 있고 main.py와 run_conditional --final에서만 열린다.

9월 구간은 두 번 열렸다. 첫 번째는 이전 버전(v2) 개발 중이었고 두 번째는 C-BAT를 동결한 뒤 한 번 연 것이다. C-BAT로 연 뒤에는 모델을 조정하거나 다시 돌리지 않았다. 그 뒤의 잡음 변형, 어텐션 기준일, 2계층 피크 모형, 앙상블 실험은 f1–f4에서만 사전 등록한 채택 규칙으로 평가했고 어느 것도 채택되지 않았다. 9월이 이미 한 번 열린 적이 있으므로 모델 선택의 근거는 f1–f4 결과로 둔다.

A.5 누수 점검

누수는 자료 수준과 코드 수준에서 따로 점검했다 [26]. 자료 수준에서는 전력 곡선이 다른 날과 똑같은 복사일 122일을 찾아 목표와 기준일에서 가리고, 무작위 5-fold와 사건 단위 보류(LOEO)를 비교해 누수 규모를 잴다(leakage_v3). 무작위 교차검증은 LightGBM 기본 모형의 오차를 약 10% 낮게 추정했다.

표 16: 보고서 결과와 재현 명령. 모듈 이름 앞의 `gmst.`는 생략했다.

보고서 결과	명령	출력 폴더
복사일 누수 진단	<code>leakage_v3</code>	<code>results_v3/ch1</code>
기준 모델 개발 구간 예측	<code>robustness --out</code> <code>results_v3/robustness</code>	<code>results_v3/robustness</code>
C-BAT와 학습형 커널 비교, 주 성능표	<code>run_conditional</code> <code>--attention-ablation</code>	<code>results_v3/attention_ablation</code>
기준일 규칙 비교	<code>run_conditional</code> <code>--ref-comparison</code>	<code>results_v3/ref_ablation</code>
잡음 변형 비교	<code>run_conditional</code> <code>--noise-comparison</code>	<code>results_v3/noise_ablation</code>
피크 발생·오차 조건	<code>peak_conditions</code> (인자는 표 아래)	<code>results_v3/peak_conditions_v2</code>
유사일 비교	<code>analog_days</code>	<code>results_v3/analog_days</code>
월 최대 갱신 경보 백테스트	<code>billing_alarm</code>	<code>results_v3/billing_alarm</code>
보고서 표(주 성능, 피크 증별, 절제, 경보, 구간, 수렴)	<code>report_tables</code>	<code>results_v3/report_tables</code>
보고서 그림	<code>report_figures</code>	<code>report/figs</code>
9월 제출 예측	<code>main.py</code>	<code>results_v3/submission</code>

코드 수준에서는 모든 모델의 예측이 as-of 래퍼를 거친다. 래퍼는 d 일을 예측할 때 d 일 이후의 전력값을 모델에 넘기지 않는다. 회귀 검사는 이를 교란 실험으로 확인한다. 전력 행렬에서 $Y[d:]$ 를 10^9 으로 바꿔도 C-BAT의 예측 경로가 한 값도 바뀌지 않아야 통과한다(`tests/test_conditional_bat.py`). 같은 방식의 검사가 기본곡선(`tests/test_backbone.py`)과 LightGBM 기준 모델(`tests/test_benchmark_models.py`)에도 있다.

A.6 반복 설정과 검사

확률 모델은 시드 $0 \cdot 1 \cdot 2$ 로 세 번 적합하고 지표는 세 시드의 평균을 보고한다. 각 적합은 6,000회 반복하고 앞 3,000회를 버린다. 수렴은 기록한 모수 22개의 기본 $\text{split-}\hat{R}$ [27, 29]로 확인했고 모든 fold의 내부·외부 적합에서 최댓값이 1.03 이하였다. 9월 제출 예측은 시드 0 한 번의 적합이다.

회귀 검사는 `uv run pytest -q`로 실행하며 133개가 모두 통과한다. 검사는 과거 기준일만 쓰는지, 튜닝·보정 구간이 분리되는지, 봉인된 날이 분석에서 빠지는지, 고정 커널과 상태별 잡음이 의도대로 동작하는지, 요금시간대 마스크가 요금표와 맞는지를 확인한다.

A.7 사전 등록 기록

결과를 보기 전에 판정 규칙을 적어 둔 실험은 `document/`에 기록되어 있다.

- `BILLING_alarm_preregistration.md`: 월 최대 갱신 경보 규칙과 백테스트.

- CBAT_counterfactual_validation.md: 모형 반사실 절감액의 유사일 검증과 요금 규칙 적용.
- CBAT_ref_decision.md: 기준일 규칙 결정.
- CBAT_attnref_preregistration.md, CBAT_planref_preregistration.md: 기준일 규칙의 변형.
- CBAT_noise_variants.md: 잡음 변형 비교.
- CBAT_peak_layer_plan.md: 2계층 피크 모형.
- ENSEMBLE_preregistration.md, RISK_issuance_preregistration.md: LightGBM 앙상블과 위험확률 발행 방식.

B 모형 세부 사항

C-BAT의 모수는 표준화 단위에서 추정한다. 전력은 학습 구간 표준편차로 나누고, 생산량은 학습 구간 최댓값 $q_{\max}$ 로 정규화한다(식 2). 표 17의 사전분포 값은 모두 이 단위 기준이다.

표 17: C-BAT의 사전분포(표준화 단위). IG는 역감마(모양, 척도)다.

모수	사전분포
기본곡선 $\mu_{k,\cdot}$	$\mathcal{N}(0, \tau_k(\mathbf{R} + 10^{-4}\mathbf{I})^{-1})$, $\mathbf{R}$ 은 순환 RW2 정밀도 행렬
평활 분산 τ_k	IG(1, 0.01)
기준일 계수 γ_k	$\mathcal{N}(0, 5^2)$
로그 생산 이득 $\omega_{c,k} = \log w_{c,k}$, $k = 1, 2, 3$	$\mathcal{N}(\log 0.3, 1.5^2)$; 비가동일은 $w_{c,0} = 0$
커널 형상 $(\log \sigma, \log \beta, c)$	$(\log 1.5, \log 2, 0)$ 에 고정
날짜 효과 분산 $\sigma_{u,g}^2$	IG(2, 0.01)
혁신 분산 $\sigma_{\eta,g}^2$	IG(2, 0.01)
자기상관 ρ_g	U[0, 0.98)

커널 형상을 가동유형별로 학습하는 변형에서는 $(\log \sigma, \log \beta, c)$ 에 중심 $(\log 1.5, \log 2, 0)$, 표준편차 $(0.5, 0.5, 1.0)$ 의 정규 사전분포를 둔다. 시간 가중치 ω_d (식 6)는 우도의 정밀도에만 곱하고 날짜 효과의 사전분포에는 곱하지 않는다. 혁신 분산의 조건부분포에서는 모양 모수에 관측 수 대신 가중치 합의 절반을 더한다.

한 번의 반복은 다음 순서로 진행한다.

1. 현재 ρ_g 로 결측 간격을 반영한 AR(1) 백색화 계수(식 5)를 계산한다.
2. 가동유형 $k = 1, 2, 3$ 마다 두 로그 이득 $\omega_{\cdot,k}$ 에 보폭 0.5의 정규 랜덤워크를 제안하고, $(\mu_{k,\cdot}, \gamma_k)$ 를 적분한 주변우도와 사전분포로 채택 여부를 정한다. 학습 자료에 그 유형이 없으면 사전분포에서 뽑는다.
3. 가동유형마다 $(\mu_{k,\cdot}, \gamma_k)$ 를 결합 정규 조건부분포에서 Cholesky 분해로 한꺼번에 뽑는다.

4. 평활 분산 τ_k 를 역감마 조건부분포에서 뽑는다.
5. 날짜 효과 u_d 를 켄레 정규 조건부분포에서 뽑는다.
6. 잡음 상태 g 마다 ρ_g 를 보폭 0.04의 랜덤워크 Metropolis로 갱신하고, $\sigma_{\eta,g}^2$ 와 $\sigma_{u,g}^2$ 를 역감마 조건부분포에서 뽑는다.

6,000회를 반복해 앞 3,000회를 버리고, 남은 3,000개를 사후표본으로 저장한다. 초기값은 $\omega_{c,k} = \log 0.3$, $\mu_{k,\cdot}$ 는 가동유형별 학습 평균 곡선, $\gamma_k = 0$, $\rho_g = 0.5$ 이다.

C 경진대회 만족도 조사 완료 화면

설문 주소: <https://naver.me/FetWt7SN>

(설문 완료 화면 캡처를 여기에 넣는다)